



Umelá inteligencia 2025



Ivan Sekaj, Ústav robotiky a kybernetiky, FEI STU BA
ivan.sekaj@stuba.sk

Úvod a motivácia


Motivácia



Motivácia



Motivácia



Motivácia




Prirodzená inteligencia

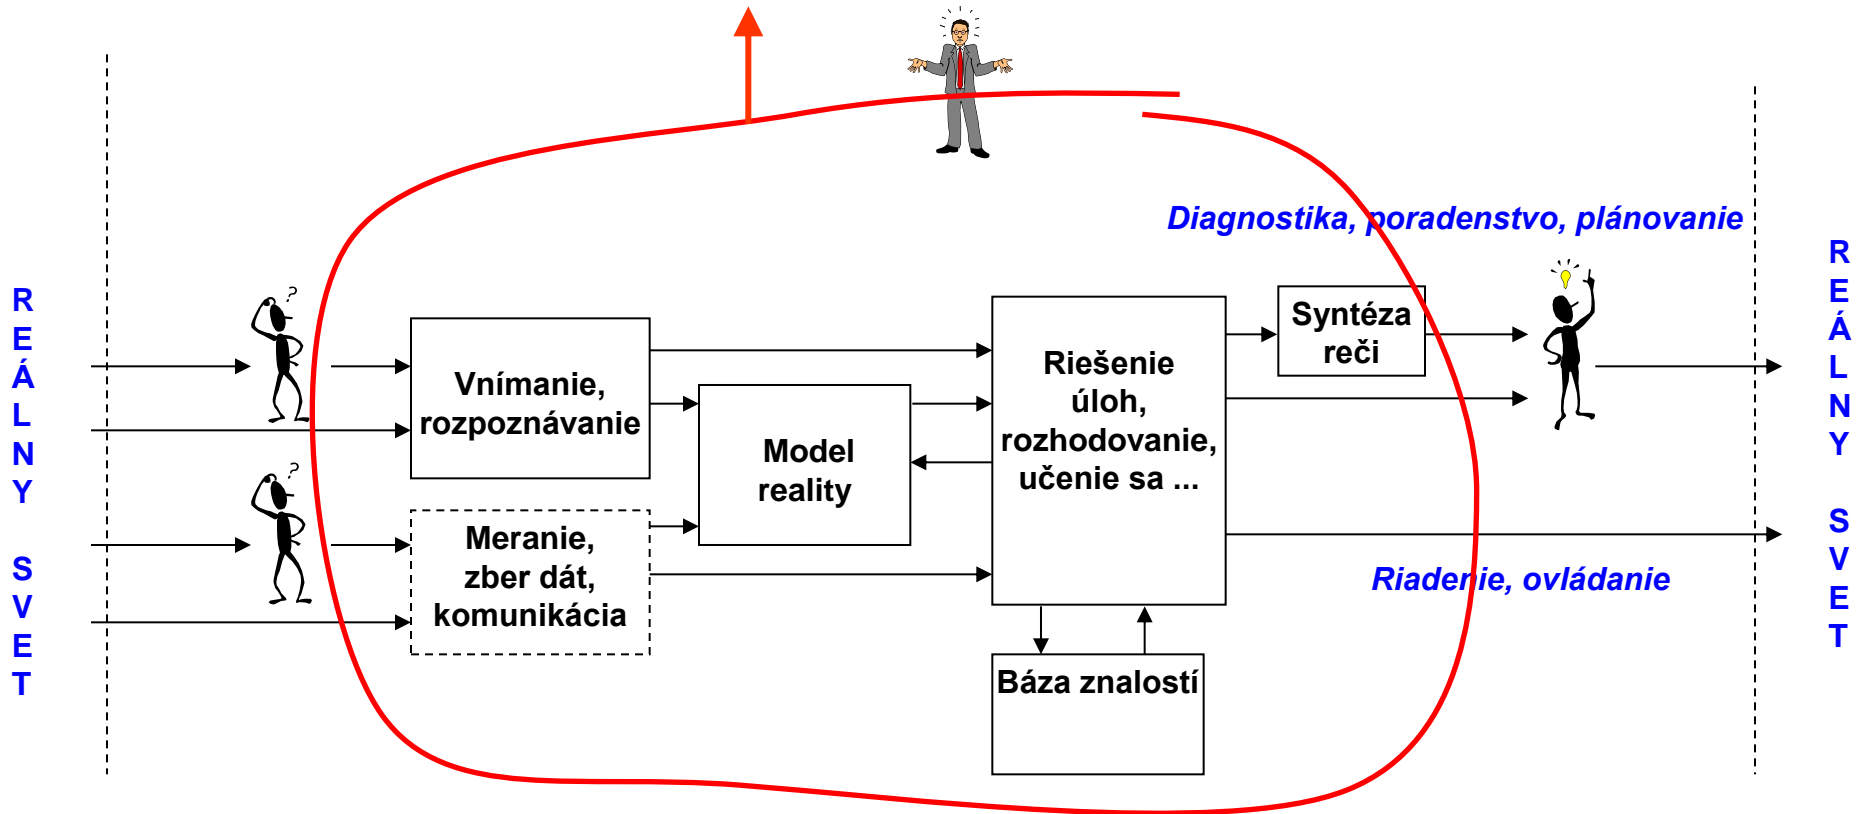


Prirodzená inteligencia je vlastnosťou živých organizmov vyjadrujúca mieru ich schopnosti efektívne reagovať na prejavy prostredia a aktívne ich využívať vo svoj prospech.

- Môžu stroje myslieť ?
Môžu počítače napodobniť alebo nahradiť prirodzenú inteligenciu ?
- Snaha napodobniť prirodzenú inteligenciu → **umelá inteligencia**



Umelá inteligencia



“Výpočtová inteligencia” (Computational intelligence, Soft computing)

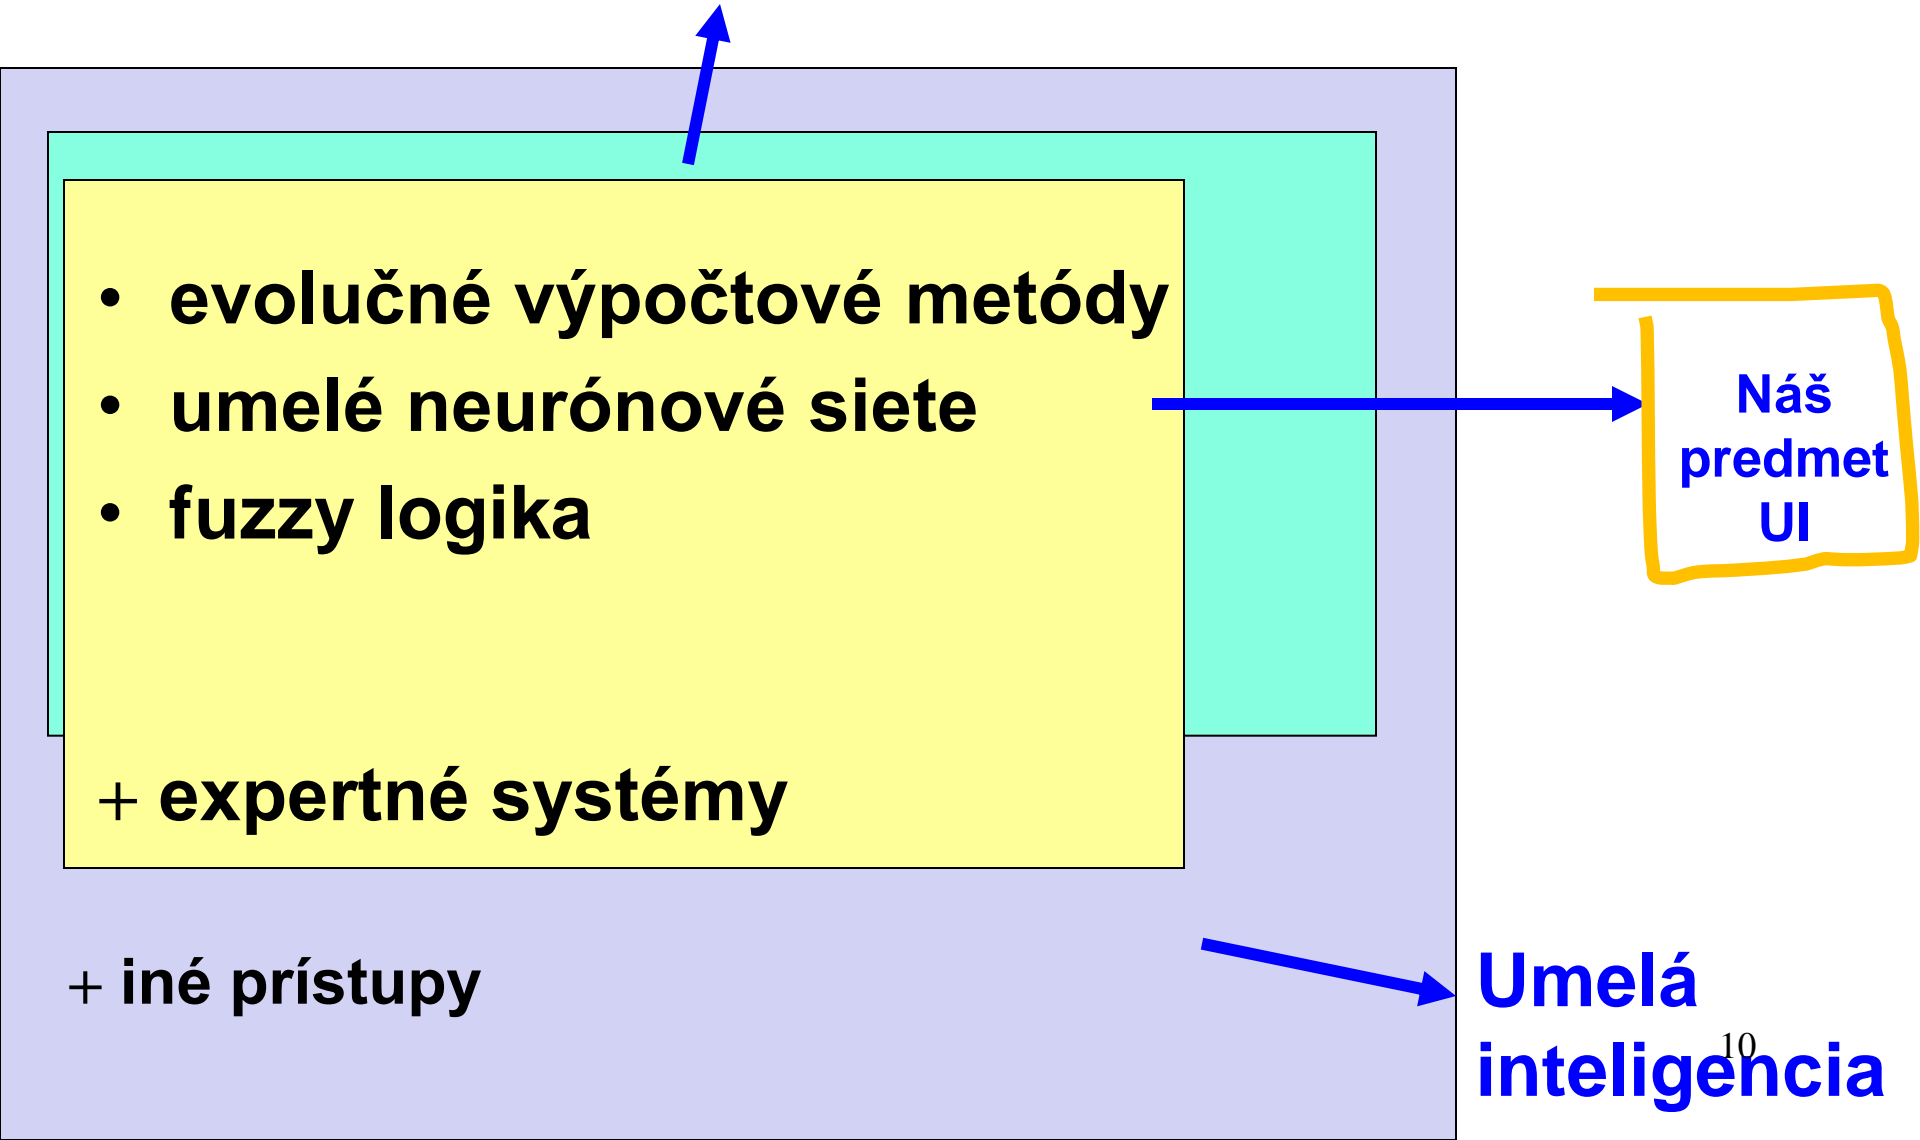
- evolučné výpočtové metódy
- umelé neurónové siete
- fuzzy logika

+ expertné systémy

+ iné prístupy


Náš
predmet
UI

Umelá
inteligencia¹⁰




Evolučné / Genetické algoritmy

optimalizačný prístup napodobujúci evolúciu v živej prírode, vhodný na riešenie mnohých typov úloh



Umelé neurónové siete

prístup vhodný na modelovanie, predikciu,
rozpoznávanie, klasifikáciu objektov a javov,
napodobuje vnútornú štruktúru mozgu




Fuzzy logika

znalostný systém napodobujúci ľudské uvažovanie
a rozhodovanie pravidlového typu,
ktoré sú formulovateľné ľudskou rečou



Exaktné



Fuzzy



Expertné systémy

napodobenie schopnosti expertov (odborníkov v danej oblasti) uchovávať znalosti a používať ich pri riešení praktických úloh

Ciel' predmetu UI

- **Oboznámit' sa so základmi
vybraných prístupov UI**
- **Tvorba jednoduchých aplikácií UI pri
riešení praktických problémov**

Obsah predmetu UI

- **základy evolučných výpočtových metód, základy genetických algoritmov (GA)**
- **aplikácie GA pri riešení problémov**
- **základy umelých neurónových sietí (UNS)**
- **použitie UNS**
- **UNS v praktických aplikáciách**
- **fuzzy logika (FL)**
- **expertné systémy (ES)**
- **súčasný stav a perspektívy UI**

Prehľad cvičení

1. Úvod, úloha 1: 2 body (Horolezecký alg.)
 2. Úloha 2: 4 bodov (Genetic) 1. blok
 3. Úloha 3: 4 bodov (Genetic)
 4. Úloha 4: 5 bodov (Genetic)
 5. Odovzdávanie úloh 1-4 (test na prednáške 5)
 6. Úloha 5: 3 body (Neuro) 2. blok
 7. Úloha 6: 4 bodov (Neuro)
 8. Úloha 7: 4 bodov (Neuro)
 9. Úloha 8: 6 bodov (Neuro)
 10. Odovzdávanie úloh 5-8 (test na prednáške 5)
 11. Úloha 9: 8 bodov (Fuzzy) 3. blok
 12. Odovzdávanie úlohy 9
- Projekty sa odovzdávajú osobne svojmu učiteľovi na cvičení, v priebehu 3 viactýždenných blokov. Omeškanie týždeň po termíne: 50% bodov. Neskôr: 0%.
 - Bonusové úlohy (konzultovať so Sekajom) +10 bodov.

Hodnotenie

Cvičenia $2+4+4+5+3+4+4+6+8=40$ b

Testy (prednášky)..... $5+5 = 10$ b

Bonusová úloha..... 10 b


Skúška 50 b

Spolu : **110 b**

Podmienka pre získanie zápočtu: 25 bodov z cvičení


Podmienka pre získanie skúšky: 15 bodov zo skúšky

Prostredie používané na cvičeniach



krátky_kurz_Matlab.pdf

Web:



**MATLAB
for
Beginners**



**Bio-inšpirované
optimalizačné výpočtové
prístupy**

The diagram consists of three nested ellipses. The outermost ellipse is light green and contains the text 'Bio-inšpirované optimalizačné výpočtové prístupy'. Inside it is a light blue ellipse containing the text 'Evolučné algoritmy'. The innermost ellipse is light red and contains the text 'Genetický algoritmus a genetické programovanie'. The ellipses are nested, indicating that genetic algorithms and programming are a subset of evolutionary algorithms, which are a subset of bio-inspired optimization approaches.


Evolučné algoritmy

**Genetický algoritmus a
genetické programovanie**

Optimalizácia a aplikačné domény optimalizačných metód

Matematika

- extremalizácia funkcií
- kombinatorika
- grafové úlohy
- regresná analýza
- teória hier, optimálne stratégie
- a veľa iného ...





Ekonomía a finančníctvo

- **optimalizácia výrobného sortimentu**
- **plánovanie výroby**
- **dopravné úlohy**
- **alokácia investícií**
- **optimalizácia finančných operácií**
- **a veľa iného ...**



Príklady koštrukčných úloh



Informatika a komunikácia

- **optim. spojenia v poč./telekom. sieti**
- **de / šifrovanie**
- **automatizované programovanie**
- **strojové učenie**
- **porozumenie textu, reči, vyhodnotenie, automatizované spracovanie, ...**
- **?**



Automatizácia, robotika



1 Genetický algoritmus



1.1 Optimalizácia, hl'adanie riešení

Optimalizačná úloha

Lokálny extrém - lokálne maximum:

$$\mathbf{x}_{\text{opt}} \in P$$

pre všetky $\mathbf{x} \in P$: $f(\mathbf{x}_{\text{opt}}) > f(\mathbf{x})$

P je podpriestor D (P - okolie lokálneho extrému)

D je podpriestor \mathbb{R}^N , (D – celý prehl'adávaný priestor, definičný obor)


N – počet optimalizovaných premenných
(dimenzia problému)

Globálny extrém - globálne maximum:

$$\mathbf{x}_{\text{opt}} \in D$$

Globálne maximum

Lokálne maximum




Globálne minimum

Lokálne minimum


x_2 -500 -500 x_1

$$\mathbf{X}^* = [x_1^*; x_2^*] = ? ; F(\mathbf{X}^*) \rightarrow \max$$

**unimodálna funkcia
má 1 extrém – minimum
(maximum)**



**multimodálna funkcia
má viac lokálnych extrémov,
jeden globálny extrém
(niekedy viac rovnakých)**



Optimalizovaný problém (matematický, technický, ekonomický, ...)

Optimalizovaný objekt (potenciálne riešenie):


$$X_i = \{x_{i,1} \ x_{i,2} \ x_{i,3} \ \dots \ x_{i,n}\}$$

$x_{i,j}$ – parametre pevnej štruktúry objektu
alebo

$x_{i,j}$ – kód štrukturálnych väzieb objektu

$x_{i,j}$ – kombinácia oboch

$$X_{\text{opt}} = ?$$



*Ohraničený priestor
potenciálnych riešení*

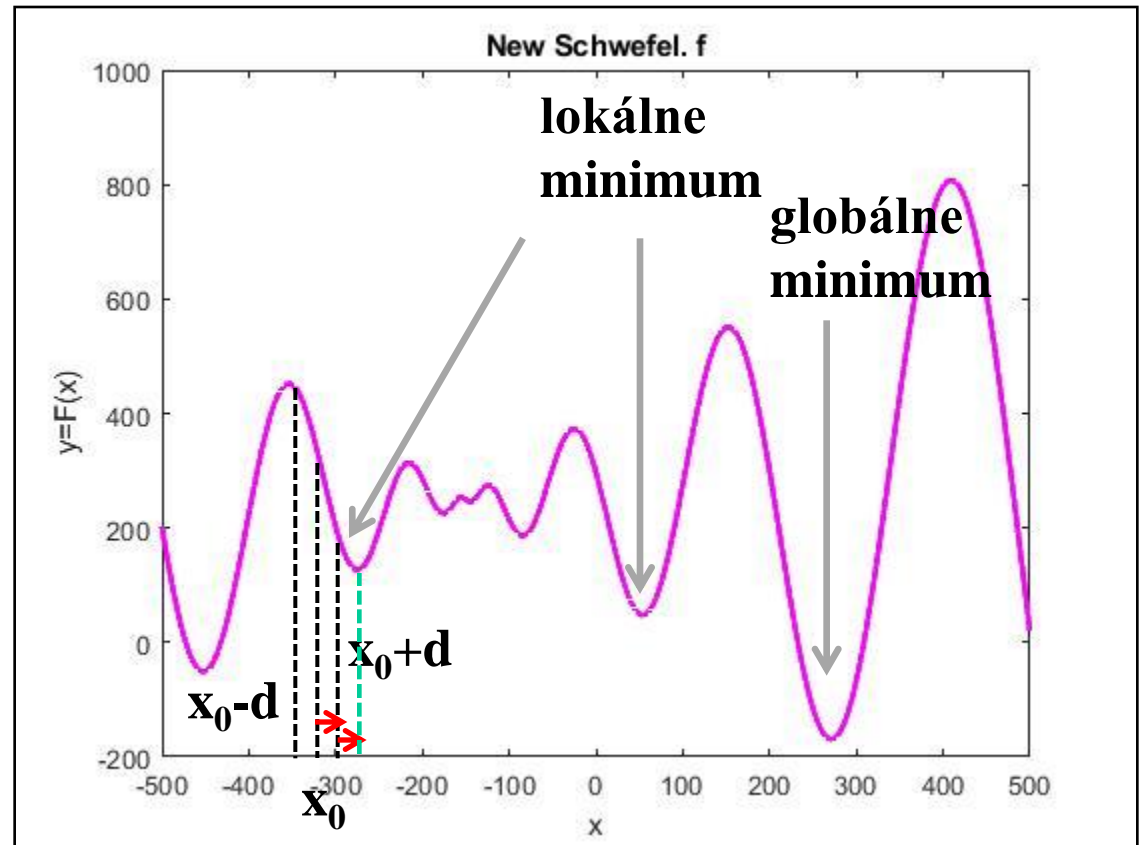
účelová funkcia : $F(X_{\text{opt}}) \rightarrow \min \ (\max)$

F – matematicky formulovaná funkcia

F – procedúra na vyhodnotenie úspešnosti daného riešenia
(výpočet, program, počítačová simulácia, ...)


Horolezecký algoritmus (Hillclimbing alg.)

1. začni v náhodnom bode x_0 def. oboru na osi x , vyhodnoť funkciu $y=F(x_0)$
2. prehľadaj susedov naľavo a napravo vo vzdialenosti 1 kroku d , vyhodnoť funkciu v bodoch $y=F(x_0-d)$, $y=F(x_0+d)$
3. ak je hodnota funkcie v niektorom z týchto bodov menšia, premiestni aktuálne riešenie do tejto novej pozície
4. ak už nie je nájdená menšia hodnota y alebo bol uskutočnený už požadovaný počet krokov, skonči, inak pokračuj v bode 2

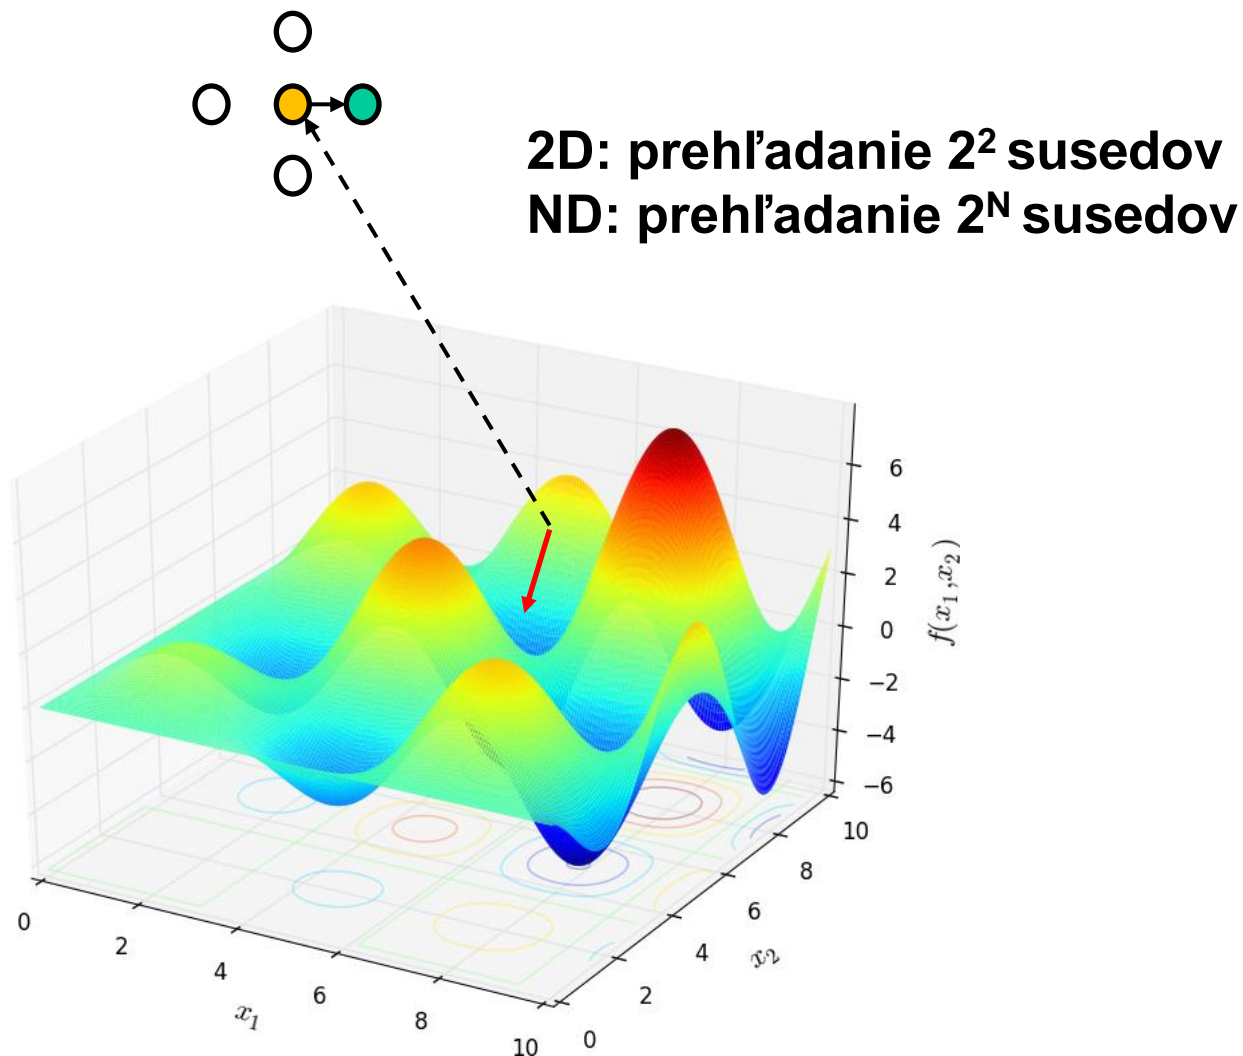


Stochastický horolezecký algoritmus

1. začni v náhodnom bode x_0 def. oboru na osi x , vyhodnot' funkciu $y=F(x_0)$
2. prehľadaj susedov naľavo a napravo vo vzdialenosti 1 kroku d , vyhodnot' funkciu v bodoch $y=F(x_0-d)$, $y=F(x_0+d)$
3. ak je hodnota funkcie v niektorom z týchto bodov menšia, premiestni aktuálne riešenie do tejto novej pozície
4. ak už nie je nájdená menšia hodnota y alebo bol uskutočnený už požadovaný počet krokov, preskoč na náhodný bod v priestore, inak pokračuj v bode 2




Horolezecký algoritmus - 2D úloha



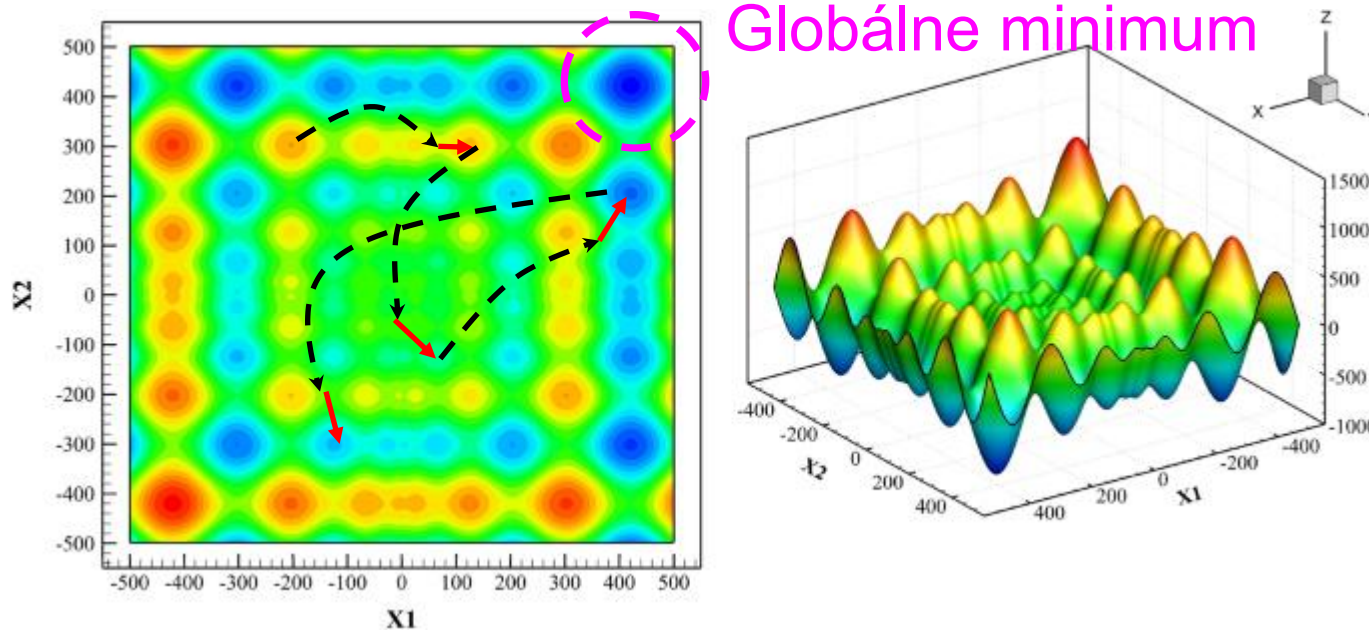
Horolezecký algoritmus uviazne v najbližšom lokálnom extrémе.

Stochastický Horolezecký algoritmus - 2D úloha

1. začni v náhodnom bode $[x_0, y_0]$ def. oboru na osiach x, y . Vyhodnot' funkciu $z=F(x_0, y_0)$.
2. prehľadaj susedov naľavo a napravo, hore a dolu vo vzdialenosti 1 kroku o veľkosti d .
3. ak je hodnota funkcie v niektorom z týchto bodov menšia, premiestni aktuálne riešenie do tejto novej pozície. Pokračuj v bode 2.
4. ak už nie je nájdená menšia hodnota, skoč na iný náhodný bod priestoru. Pokračuj v bode 2.



2D úloha – Schwefelova funkcia



10D úloha / 100D úloha

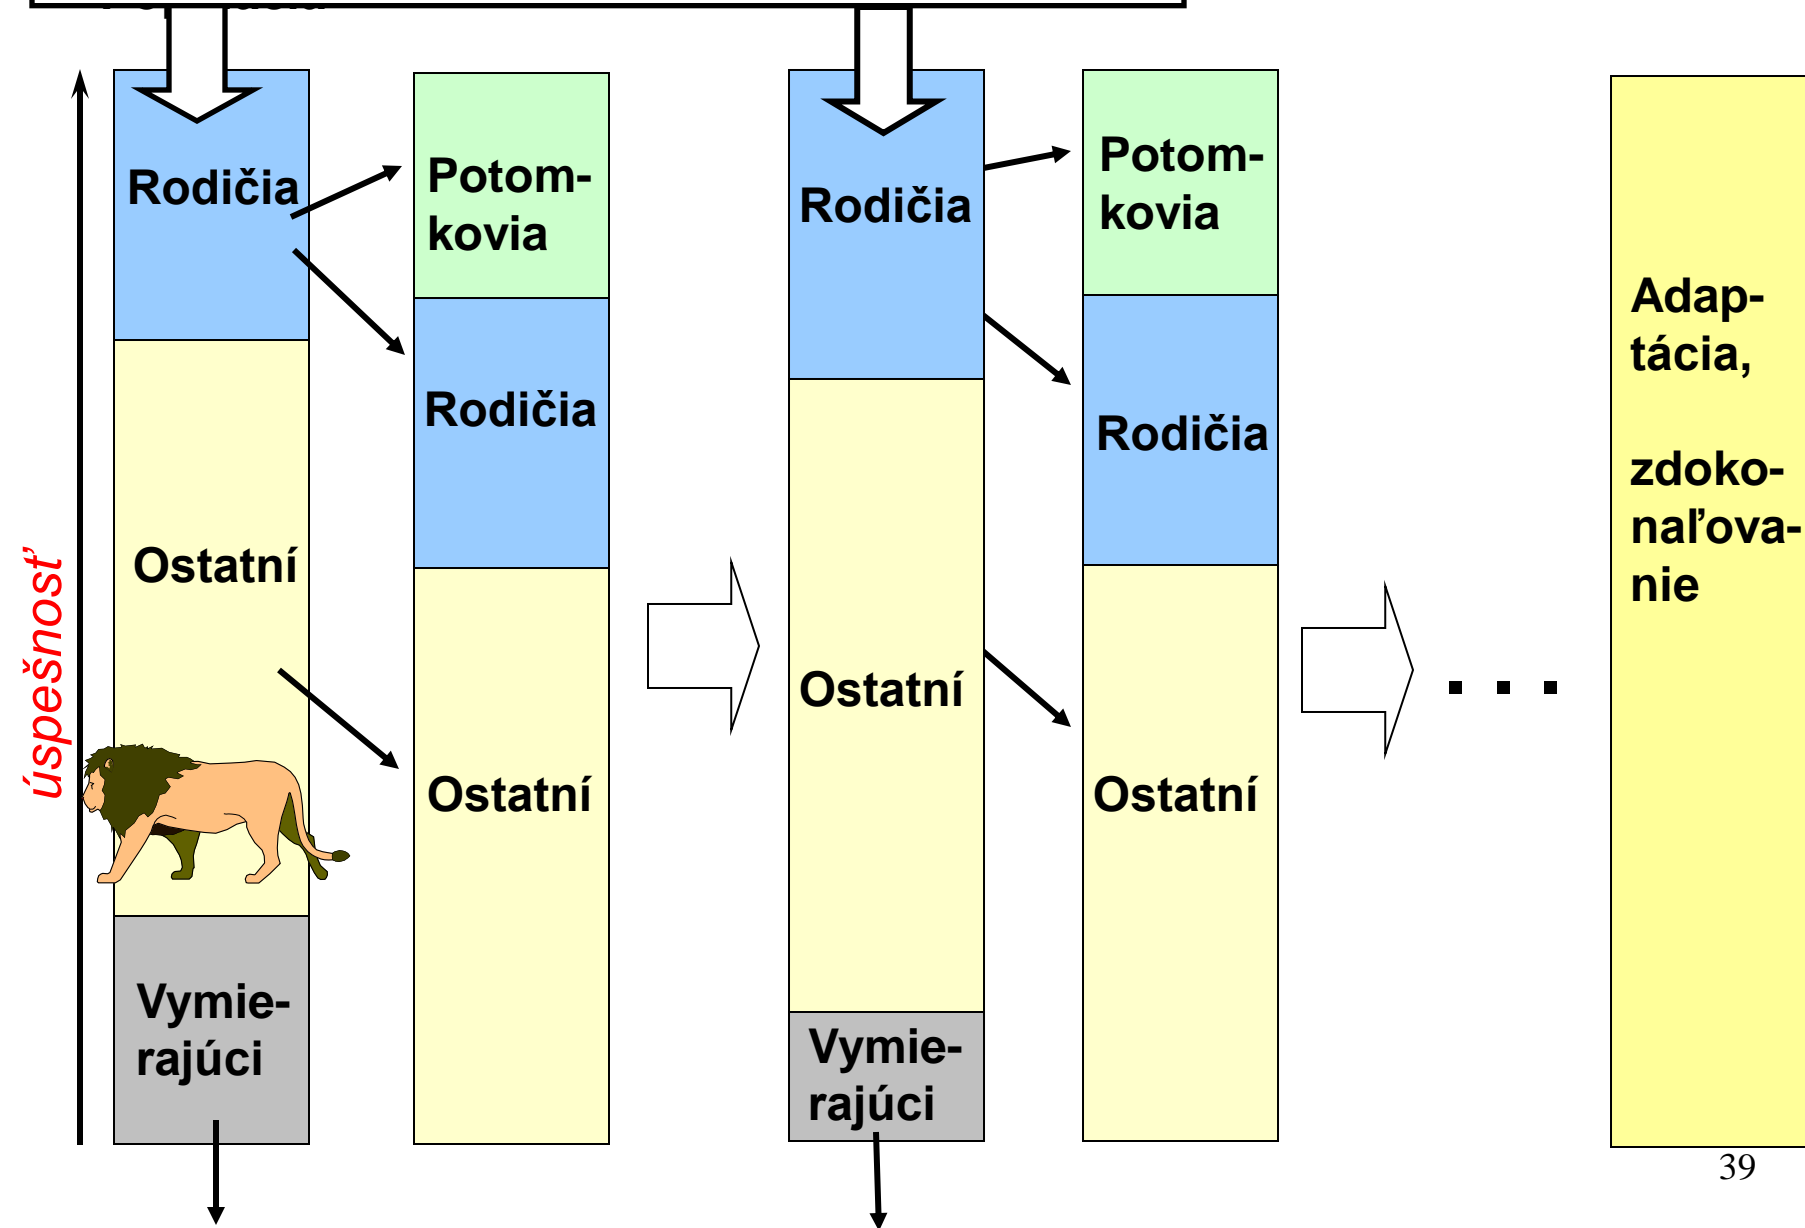
Použitie Horolezeckého algoritmu ?

Pre viac než 3D úlohu začína byť použitie Horolezeckého algoritmu výpočtovo neúnosné.

1.2 Genetický algoritmus, úvod


Zjednodušený model evolúcie v prírode

*Vplyvy prostredia, boj o prežitie,
konkurenčný boj o potravu, zápas o partnerov*




Genóm – kompletná genetická informácia daného jedinca

chromozómy




Človek má 3 mld. nukleotídových báz, 30 000 génov

Genóm predstavuje kompletnú informáciu o stavbe tela a biologických vlastnostiach konkrétneho jedinca




Gény sú postupnosti nukleotídových báz, ktoré reprezentujú informácie o jednotlivých elementárnych vlastnostiach jedinca

Charles Darwin




fenotyp

„genóm“




genotyp



Kríženie chromozómov dvoch rodičov
– kombinácia génov rodičov u potomkov


Mutácia chromozómov



Mutácia – náhodná zmena génov potomka oproti génom získaným od rodičov - nové vlastnosti.

Vzniká pôsobením vonkajších vplyvov ako UV žiarenie, chemické vplyvy, tepelné vplyvy ...

Mutácia chromozómov



ACACTGGAACTGAGACACGGTCCAGACTG
GGGGAAACCCCTGAAGCAGCAACGCCCGGT
TTAGGGGAAGAAACCATGACGGTACCTAACG
GTAATACGGAGGGTGCAGCGTTACTCGG
AAGTCTTTTGTGA MUTATION AATCT
ATCTAGAGTGAGGGAGAGGCAGATGGAA
GGAAATACCCATTGCGAAGGCGATCTGCT
AGCAAACAGGATTAGATACCCCTGGTAGT
CTAGTCACGGCAGTAAATGCACCTAACGG



DELETION



DUPLICATION



INVERSION



TRANSLOCATION



Boj o prežitie s predátormi, zápas o potravu, zápas o partnerov, snaha odolávať a prispôsobiť sa prírodným podmienkam → prežitie najschopnejších

Prirodzený výber



Evolúcia



1 bunka - baktéria

6000 miliárd buniek - človek

Napodobenie prirodzenej evolúcie pri počítačovom riešení praktických úloh:

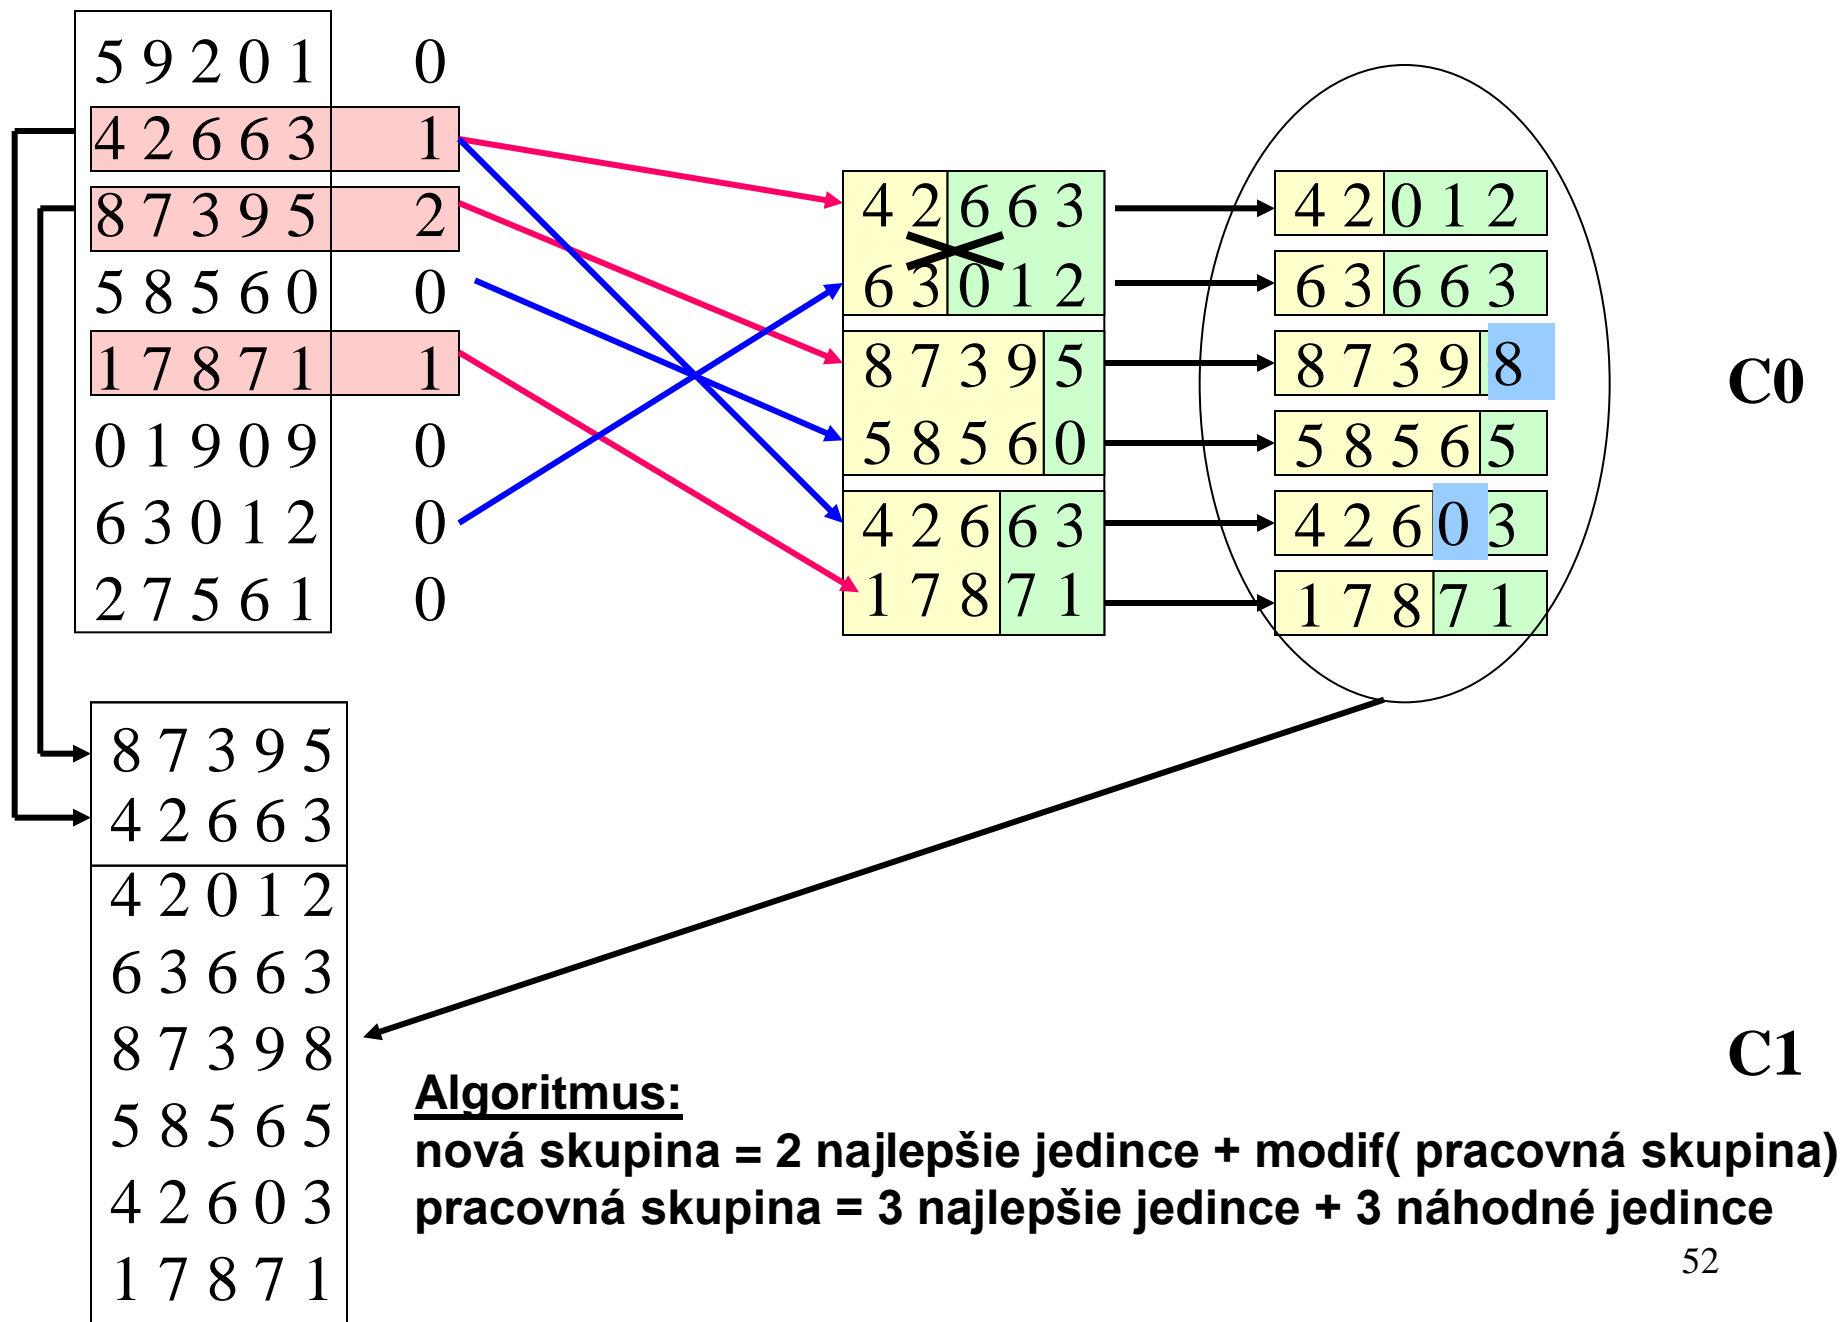
**Evolučné výpočtové prístupy
(Evolučné algoritmy)**

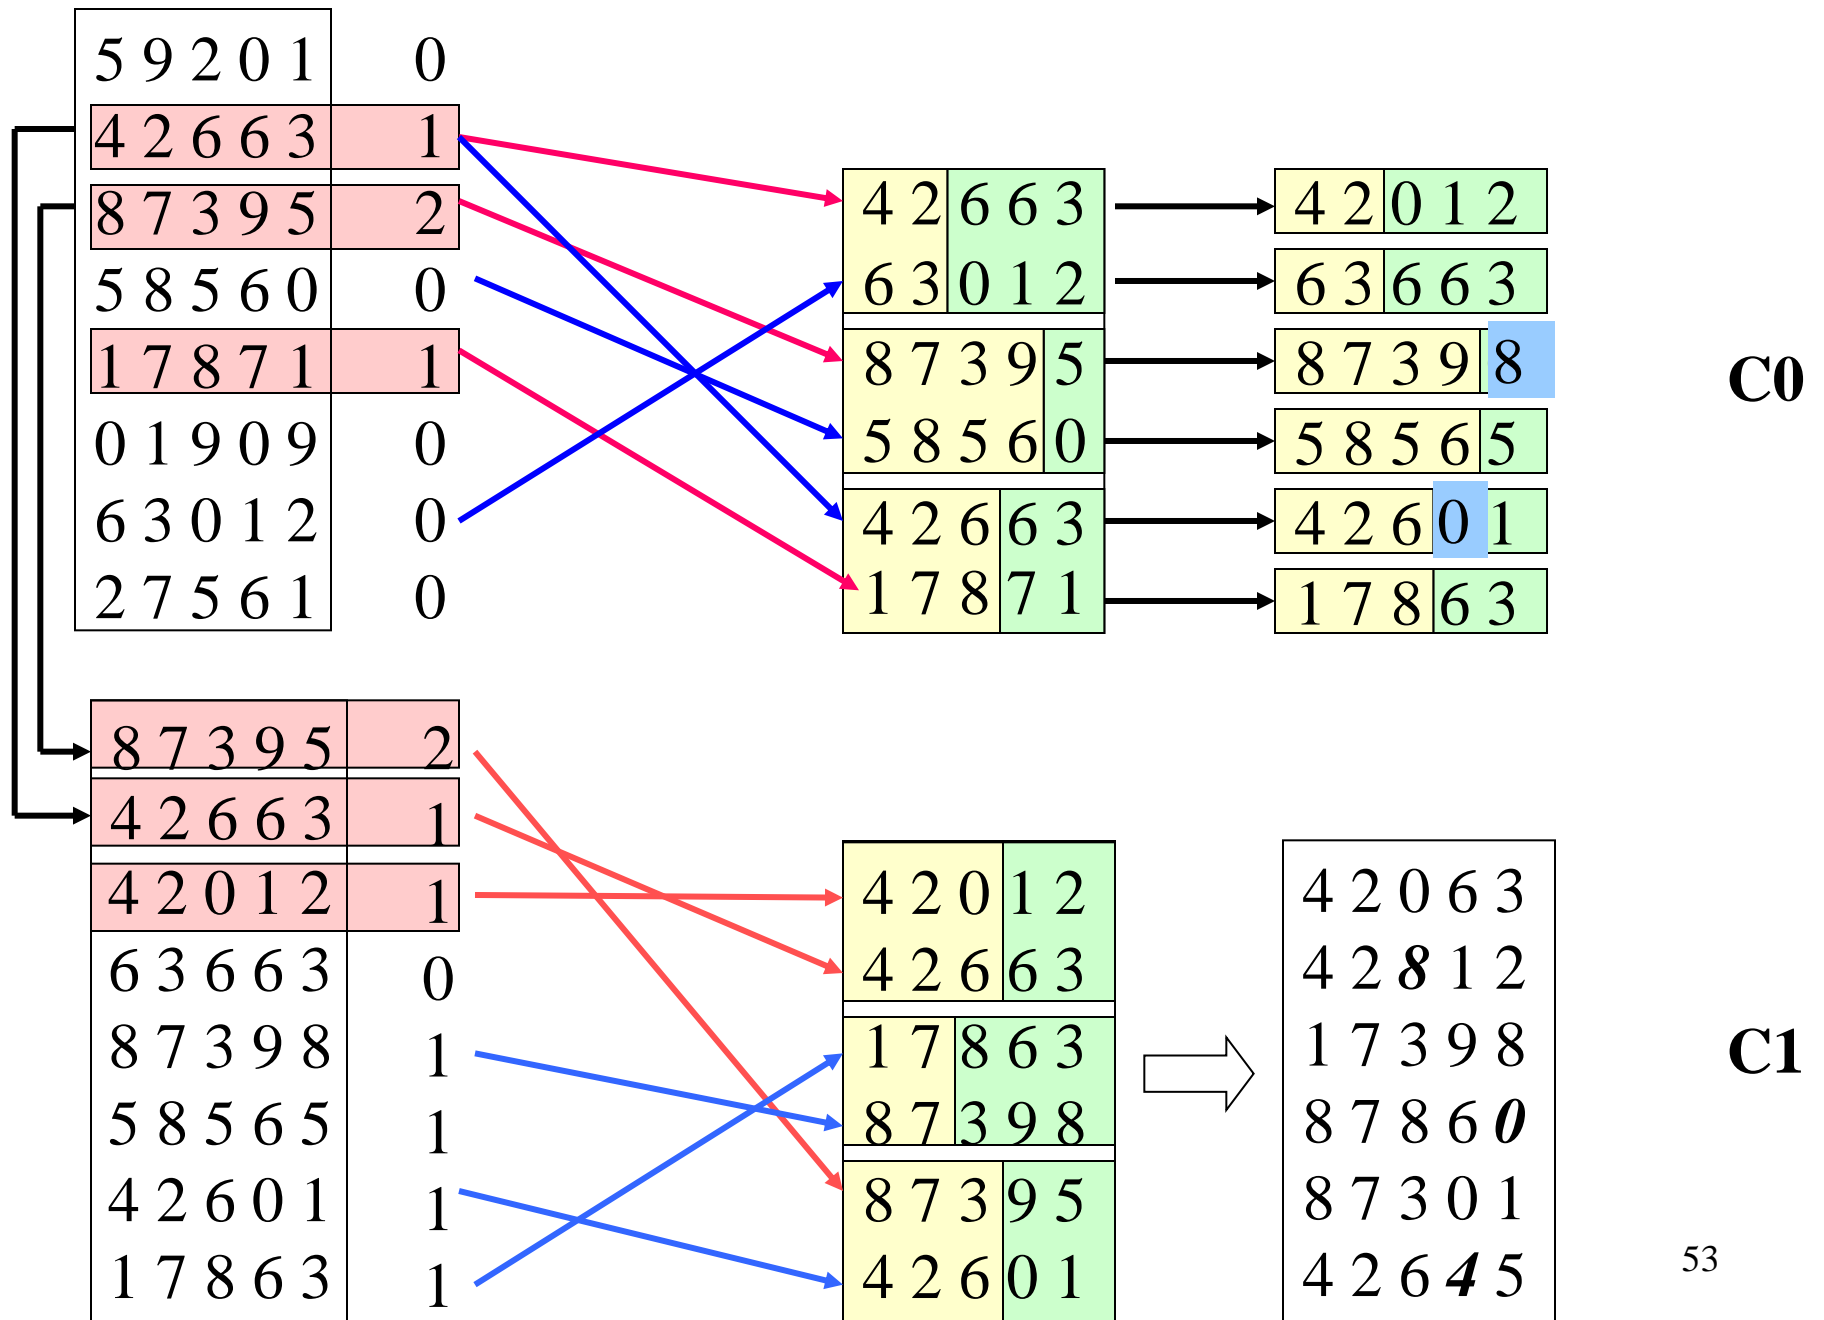
Reprezentanti evolučných výpočtových prístupov

- **Evolučné stratégie (numerické úlohy)**
- **Evolučné programovanie**
- **Genetické algoritmy**
- **Genetické programovanie (evolúcia štruktúr, programov)**
- **Diferenciálna evolúcia (numerické úlohy)**
- **Umelý imunitný systém**
- **iné (PSO, Kolónie mravcov, Kultúrne algoritmy, HSO, ... , umelý život)**
- **Iné ...**


Príklad:

**„hádanie 5-ciferného čísla“
(1 2 3 4 5)**





8 7 3 9 5	2
4 2 6 6 3	1
4 2 0 6 3	1
4 2 8 1 2	1
1 7 3 9 8	2
8 7 8 6 0	0
8 7 3 0 1	1
4 2 6 4 5	3




1 7 3 9 8
4 2 6 4 5
4 2 0 6 3
8 7 8 6 0
8 7 8 6 0
8 7 3 9 5



1 2 6 4 5
4 7 3 9 8
4 2 0 6 0
8 7 1 6 3
8 7 3 9 5
8 7 8 6 0

C2

4 2 6 4 5	3
8 7 3 9 5	2
1 2 6 4 5	4
4 7 3 9 8	1
4 2 0 6 0	1
8 7 1 6 3	0
8 7 3 9 5	2
8 7 8 6 0	0




4 2 0 6 0
4 2 6 4 5
4 2 6 4 5
8 7 3 9 5
8 7 8 6 0
1 2 6 4 5



4 2 0 6 5
4 2 6 4 0
0 2 7 9 5
8 7 6 4 5
8 7 6 4 5
1 2 8 6 0

C3

1 2 6 4 5	4
4 2 6 4 5	3
4 2 0 6 5	2
4 2 6 4 0	2
0 2 7 9 5	2
8 7 6 4 5	2
8 7 6 4 5	2
1 2 8 6 0	2




1 2 8 6 0
4 2 6 4 5
1 2 6 4 5
0 2 7 9 5
8 7 6 4 5
4 2 0 6 5



1 2 6 4 8
4 2 8 6 0
1 2 7 9 5
0 2 6 4 5
8 7 6 6 5
4 2 3 4 5

C4

1 2 6 4 5	4
4 2 6 4 5	3
1 2 6 4 8	3
4 2 8 6 0	1
1 2 7 9 5	3
0 2 6 4 5	3
8 7 6 6 5	1
4 2 3 4 5	4



8 7 6 6 5
4 2 8 6 0
4 2 6 4 5
1 2 6 4 5
1 2 7 9 5
4 2 3 4 5



8 7 6 3 0
4 2 8 6 5
4 9 6 4 5
1 2 6 4 5
1 2 3 4 5
4 2 7 9 5

C5

1.3 Základné objekty a pojmy v GA

- **Ret'azec (chromozóm)**
- **Gén**
- **Populácia**
- **Generácia**
- **Účelová funkcia (Fitness)**

Ret'azec

je do postupnosti čísel alebo symbolov zakódovaná množina parametrov optimalizovaného objektu

- **binárny ret'azec :**
[1 0 0 1 1 1 1 0]
- **celočíselný ret'azec :**
[2 7 7 9 0 5 3]
- **reálne-číselný ret'azec :**
[7.1 2 10 0.02 258 99.9]
- **symbolový ret'azec :**
[NB Z PS PM modrý zásaditý]
- **a ich kombinácie**

Príklady reťazcov

- **Počty x_i vyrobených výrobkov v_1, v_2, \dots, v_n**
 $r = [x_1, x_2, x_3, \dots, x_n]$
- **Konštrukčné parametre robota p_1, p_2, \dots, p_n**
 $r = [p_1, p_2, p_3, \dots, p_n]$
- **Parametre PID regulátora**
 $r = [P, I, D]$

Permutačné kódovanie reťazcov

Spôsob zakódovania takého typu reťazcov, ktoré reprezentujú potenciálne riešenia úloh hľadania:

- optimálneho poradia prvkov
- optimálnej postupnosti operácií a pod.

gény reťazcov sú poradové čísla
(celé čísla od 1 do N)

[2 5 3 6 7 1 4 8]
[1 2 3 4 8 7 6 5]

Príklad reťazcov s permutačným kódovaním

- Poradie vykonaných výrobných operácií
 O_1, O_2, \dots, O_n
 $r = [2, 5, \dots, 7]$
- Poradie vybavovania zákazníkov
- $r = [1, 15, \dots, 7]$
- Poradie prejdéných miest

Populácia

je skupina (vhodnej veľkosti) reťazcov v danej časovej etape resp. v danom výpočtovom cykle (v danej “generácii”)

Príklad celočíselnej populácie:

```
[ 1 2 3 4 5 6 7  
  5 8 9 3 0 1 3  
  8 1 1 1 0 2 7  
  . . .  
  8 9 1 9 9 0 6 ]
```

Účelová funkcia

(kriteriálna f., objective.f.)


- predstavuje samotnú podstatu optimalizovaného problému
- vyjadruje mieru vhodnosti daného potenciálneho riešenia a cieľom je nájsť riešenie s jej minimálnou resp. maximálnou hodnotou
- jej výstupnými hodnotami sú skalárne (obyčajne reálne-číselné) hodnoty

„Fitness“ (funkcia) – účelová funkcia v terminológii GA, my budeme fitness minimalizovať (GA toolbox Matlab)


1.4 Základné genetické operácie

- **Kríženie**
- **Mutácia**
- **Výber (selekcia)**
- **kombinované**

Kríženie




rodičovské reťazce




potomkovské reťazce

Kríženie v celej populácii




■ ■ ■

Mutácia



Mutácia v rámci populácie



Pravdepodobnosť mutácie jedného génu v rámci celej populácie je zvyčajne od 0.1 – 10%

Mutácie rôznych typov reťazcov

1 1 0 1 0 0 0 1 0

1 1 0 1 0 **1** 0 1 0

7.2 5.03 1999 0.001

7.2 **17.5** 1999 0.001

O₂ H CO₂ S Zn Fe H₂SO₄

O₂ H CO₂ S **Si** Fe H₂SO₄

Výber


Úlohou výberu je:

- vybrať potrebný počet reťazcov (rodičov), ktoré budú modifikované pomocou genetických operácií,
- vybrať reťazce, ktoré sa nezmenené dostanú do novej generácie.

Existuje viacero typov výberu.

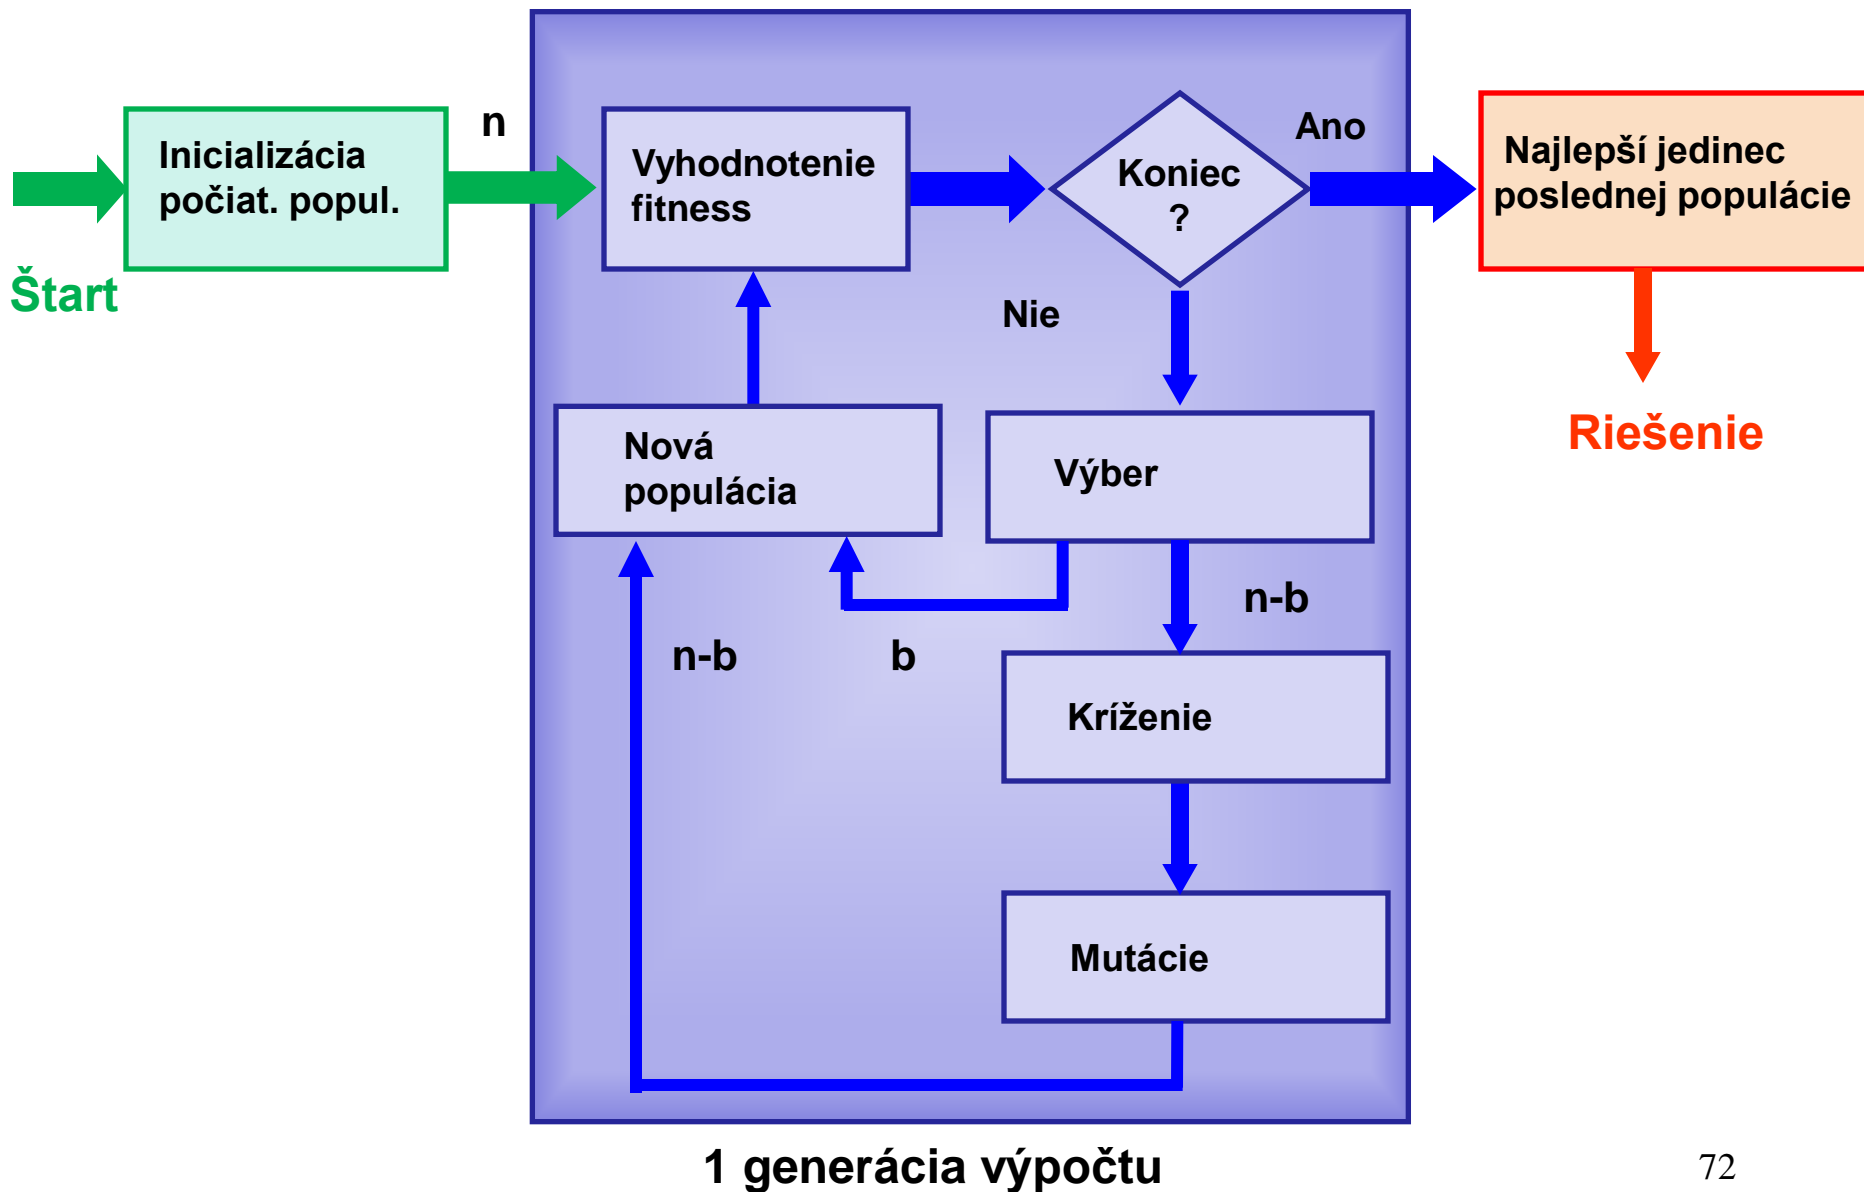
Pri výbere platí: úspešnejšie reťazce majú väčšiu pravdepodobnosť byť vybrané než menej úspešné.

Rovnomerný váhovaný ruletový výber (selsus.m)




1.5 Genetický algoritmus (GA)

Genetický algoritmus



Ukončovacie podmienky GA

- testovanie splnenia vopred definovaných podmienok
- stagnácia hodnoty účelovej funkcie
- podobnosť (identita) mnohých jedincov v populácii
- ukončenie predpísaného počtu generácií (cyklov algoritmu)



Zjednodušene môžeme povedať

- **Podstatou optimalizácie pomocou GA je náhodné kombinovanie prvkov reťazcov tak, aby bola maximalizovaná ich účelová funkcia.**
- **Najhoršie kombinácie sú vylučované, najlepšie sú posúvané do ďalších generácií, kde sú kombinované s inými úspešnými reťazcami (krížené) alebo náhodne menené (mutované).**
- **Ak sa takýto cyklus mnohokrát opakuje, je možné sa priblížiť ku globálnemu optimu.**

Príklad: hľadanie globálneho minima Schwefelovej funkcie použitím genetického algoritmu (cvičenia, úloha 2)