



2. Umelé neurónové siete (UNS)



Úvod do problematiky




Uvažovanie






Paralelné vykonávanie činností



2.1 Mozog, biologické neuróny, história vývoja UNS



Neuróny




Počet neurónov niektorých živočíchov

	Počet neurónov	Počet synapsií
Caenorhabditis elegans (červ)	302	7500
Vínna muška	250 000	10^7
Mravec	250 000	
Včela	960 000	10^9
Myš domáca	71 000 000	10^{12}
Potkan hnedý	200 000 000	$4,5 \cdot 10^{11}$
Mačka	760 000 000	10^{13}
Pes	2 253 000 000	
Šimpanz	28 000 000 000	
Človek	86 000 000 000	$1,5 \cdot 10^{14}$
Slon africký	257 000 000 000	

Prenos el. signálov medzi neurónmi v M.

Na vst



Každý neurón generuje impulzy s frekvenciou f , ktoré sa šíria cez axon na iné neuróny.


Hodnota f je priamo úmerná sumárnej excitácii neurónu na jeho vstupoch.

Na f má vplyv tiež koncentrácia neuroprenášačov (neurotransmitterov) a stav chemického prostredia v M.

Synapsia


elektrický prenos impulzu
(informácie)

chemický prenos
impulzu



elektrický prenos impulzu)

Synaptické spojenie dvoch neurónov




**Rýchlosť pohybu el. náboja v
el. obvodoch je 10^6 x väčšia.
(stovky MHz / stovky Hz)**



Činnosť jedného neurónu


- ak suma všetkých vstupných potenciálov v danom okamžiku presiahne prahovú hodnotu - aktivácia neurónu, jadro po axone vyšle impulz, ktorý je distribuovaný do všetkých synáps
- na im 20- y mi je



*zhluky impulzov s frekvenciou 250-1000 impulzov / s,
frekvencia zhlukov 1-10 zhlukov za sekundu (frekvenčná
modulácia)*

Centrálna nervová sústava je hlavné nervové
radiace centrum vyšších organizmov.

Skladá sa z dvoch základných súčastí: mozgu (1) a miechy (2,3).




CNS riadi motorické reakcie organizmu, koordinuje pohyb a rovnováhu, nesie centrá životne dôležitých funkcií (dýchanie, krvný obeh, hlad, smäd..), je centrom vnímania, uvažovania, pamäte, učenia a vedomia človeka (kognitívnych funkcií).

Ľavá hemisféra

analytické myslenie
logika
veda
fakty
dáta
čísla
vôňa
miery, váhy
matematika

Pravá hemisféra

holistické myslenie
tvorivosť
intuícia
umenie
hudba
rytmus
emócie
vtip
fantázia
chute, vôňa



Čelný lalok

výkonné funkcie,
myslenie, plánovanie,
organizovanie a
riešenie problémov,
emócie, kontrola
správania, osobnosť

Motorická kôra


pohyb

Senzorická kôra

pocity

Perientálny lalok

vnímanie, výroba,
zmysel sveta,
aritmetika, pravopis



Spánkový lalok

pamäť, porozumenie, jazyk,
sluch, čuch,

Tylový lalok

vizualizácia


Biologické neuróny a motivácia vzniku umelých neurónových sietí (UNS)

- **Ludský mozog = 86 miliárd neurónov, každý neurón je spojený s asi 10 000 ďalšími neurónmi**
- **paralelné spracovanie informácií (vnemov, myšlienok, akcií ...)**
- **schopnosť sa učiť zo skúseností, z príkladov, z analógie**
- **modifikovať znalosti, zovšeobecňovať, konkretizovať, autoasociácia / heteroasociácia – samozdokonaľovanie sa**
- **funkcia mozgu ? (ako mozog myslí, čo je to vedomie, ...)**

- **klasická výpoč. tech. - vopred daný algoritmus (program), pomocou ktorého sa sekvenčne spracovávajú informácie, centrálné riadenie výpočtu**
- **mozog - veľký počet rôznych druhov spracovaní informácií súčasne (nezávisle ?) bez centrálného programu:**
 - vyhodnocovanie obrazu, zvuku, hmatu, teploty ...
 - spracovanie informácií z týchto vnemov, vyhodnocovanie situácie, klasifikácia objektov a javov
 - uvažovanie, učenie sa, rozhodnutie o adekvátnych akciách
 - realizácia akcie, hrubá motorika, jemná motorika
 - súčasné vykonávanie viacerých nezávislých činností
 - popritom riadenie (zložitých) funkcií organizmu

- **biologické neuróny pracujú o 5-6 rádov pomalšie než kremíkové hradlá (ms vs. ns)**
- **napriek tomu v mnohých ohľadoch je ľudský mozog ešte stále výkonnejší než súčasné najvýkonnejšie počítače**
- **činnosť mozgu je založená na processe učenia sa (prispôsobovania sa, korigovania znalostí) a neskôr na využití týchto schopností a znalostí vo fáze vybavovania (využitie znalostí, schopností)**

Príklady tvorivých schopností mozgu



Príklady schopností mozgu




Proces získania zručností/znalostí – trénovanie/učenie



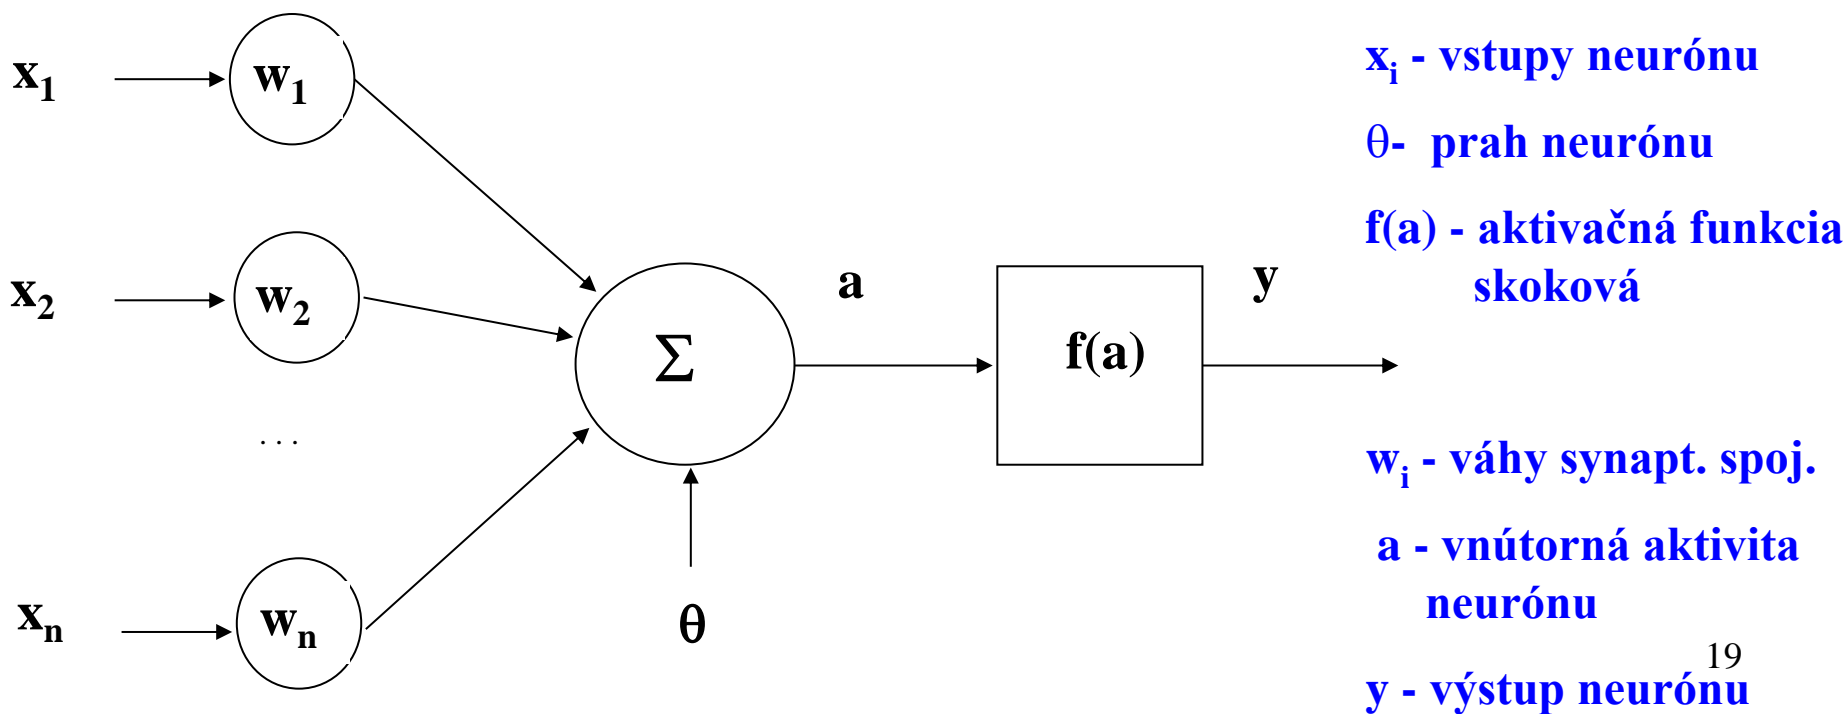
Cieľ nášho snaženia

napodobenie architektúry / funkcií biologických neurónových systémov a ich využitie pre rôzne praktické (technické, výpočtové) účely → "umelé neurónové siete" a im príbuzné systémy

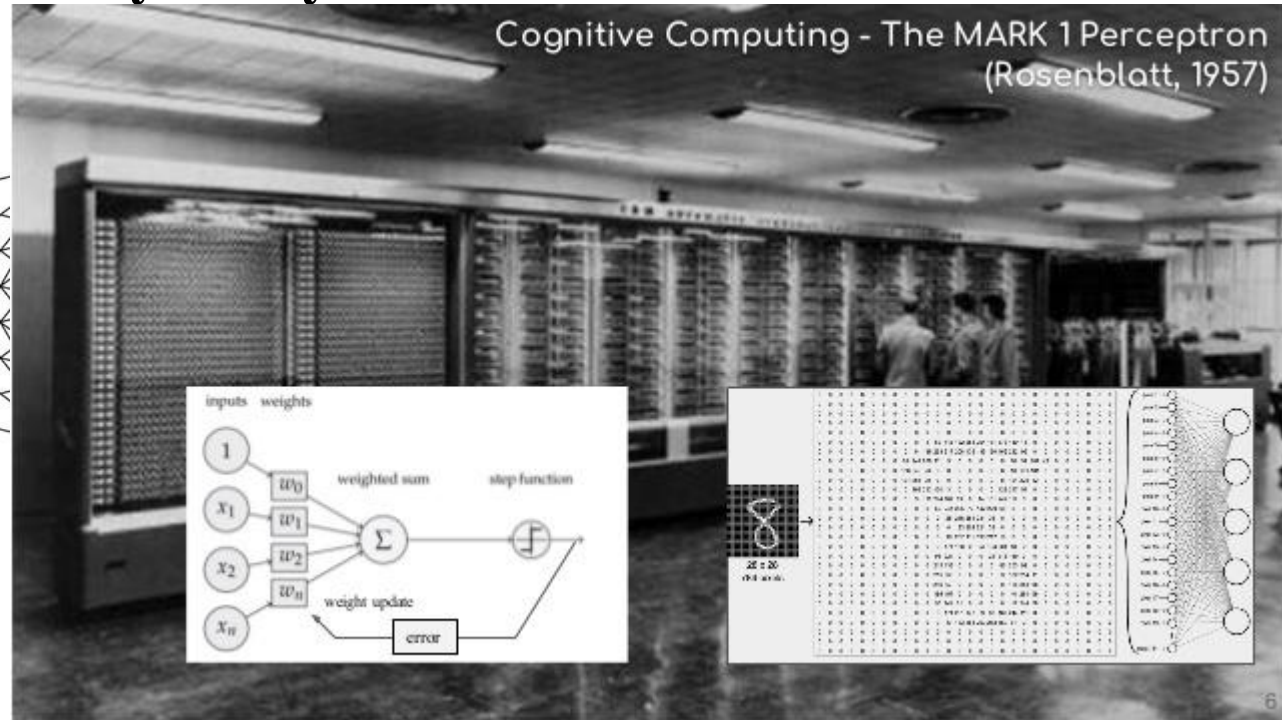



2.2 Stručná história vývoja UNS

- 1.pol. 20. stor. - W.S McCulloch, 1. významná práca o modeli neurónu
- 40. roky, W.S McCulloch, W.Pits - model neurónu v podstate používaný dodnes





- **Rosenblatt (1958) neurónová sieť – „perceptrón“. Na elektrónkovom počítači naučil sieť neurónov rozpoznávať znaky zachytené na 2D matici foto-senzorov.**



- **otázky, aké využitie nájdú neurónové siete, ako realizovať zložité transformácie a proces učenia**

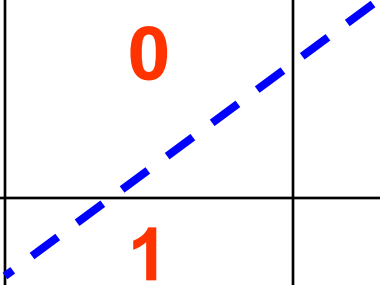
•Minsky a Papert (1969) – „ohraničenosť použitia n.s. iba na lineárne separovateľné problémy“, tento záver zovšeobecnil na všetky typy n.s.

Lineárne separovateľné a nelineárne separovateľné problémy



*Triedy A a B sú lineárne separovateľné,
triedy C a D nie sú lineárne separovateľné*

AND	0	1
0	0	1
1	1	1




AND - lineárne
separovateľný
problém

XOR	0	1
0	0	1
1	1	0

XOR- lineárne
neseparovateľný
problém

- "Ak sa nedá riešiť tento jednoduchý problém (XOR), tak sa nedajú riešiť ani oveľa zložitejšie nelineárne problémy" - Minsky a Papert vplyvom sily svojich osobností *utlmili iniciatívy a záujem* v oblasti vývoja n.s. až do 80. rokov 20. storočia.
- Až návrh algoritmu "Error Back-Propagation" (algoritmus spätného šírenia chyby, BP, 1986) priniesol univerzálne riešenie návrhu parametrov viacvrstvových n.s. Toto spôsobilo renesanciu UNS, použitie aj pre riešenie lineárne neseparovateľných problémov.
- Dnes sú UNS neodmysliteľnou súčasťou riešenia mnohých problémov: nelineárneho modelovania, klasifikácie, rozpoznávania obrazu, signálov ...
- Dnes UNS (hlboké siete, hlboké učenie...) predstavujú hlavný prúd v UI

2.3 Matematický (počítačový) neurón



$$y = \varphi\left(\sum_{i=1}^n (w_i x_i) - \theta\right) = \varphi(a)$$

x_i - vstupy neurónu

θ - prah (citlivosti) neurónu


φ - aktivačná funkcia neurónu

w_i - váhy synaptických spojení

a - vnútorná aktivita neurónu


y - výstup neurónu

Aktivačné funkcie neurónov




$$\begin{aligned}\varphi(a) &= -1 && \text{pre } a < 0 \\ \varphi(a) &= 1 && \text{pre } a \geq 0\end{aligned}$$

skoková funkcia $\langle -1; 1 \rangle$




$$\begin{aligned}\varphi(a) &= 0 && \text{pre } a < 0 \\ \varphi(a) &= 1 && \text{pre } a \geq 0\end{aligned}$$

skoková funkcia $\langle 0; 1 \rangle$




$$\varphi(a) = a$$

lineárna funkcia



$$\varphi(a) = \frac{1}{1 + e^{-\beta a}}$$




sigmoida - logistická f.



$$\varphi(a) = \operatorname{tgh}(a / 2) = \frac{1 - e^{-a}}{1 + e^{-a}}$$

hyperbolický tangens

Umelá neurónová sieť (UNS)



● Input layer


● Hidden layer

● Output layer

2.4 Rozdelenie neurónových sietí podľa architektúry


a) Vrstvové štruktúry

Jednovrstvové (resp. dvojvrstvové) siete




(napr. sieť štruktúry 2-3) úplné prepojenie, obyčajne - perceptrónové siete so skokovými aktivačnými funkciami za účelom klasifikácie do tried (iba lin. separovateľné problémy)

Viacvrstvové siete




Viacvrstvové siete obsahujú aspoň jednu skrytú vrstvu. Na obr. je trojvrstvová sieť štruktúry 2-3-1. Vstupná vrstva iba distribuuje vstupné signály, výkonnú funkciu majú len skrytá a výstupná vrstva.

Viacvrstvové siete




Príklad parametrizovanej UNS




b) Dopredné a rekurentné vrstvové štruktúry

Dopredné siete




Dopredné siete obsahujú iba väzby v smere od vstupov k výstupom. Na obr. je dopredná sieť veľkosti 3-2-3.

Rekurentné siete




Rekurentné siete sú podobné ako dopredné, ale obsahujú aspoň jednu spätnú väzbu v rámci tej istej vrstvy alebo v rámci rôznych vrstiev.

c) Iné štruktúry sietí

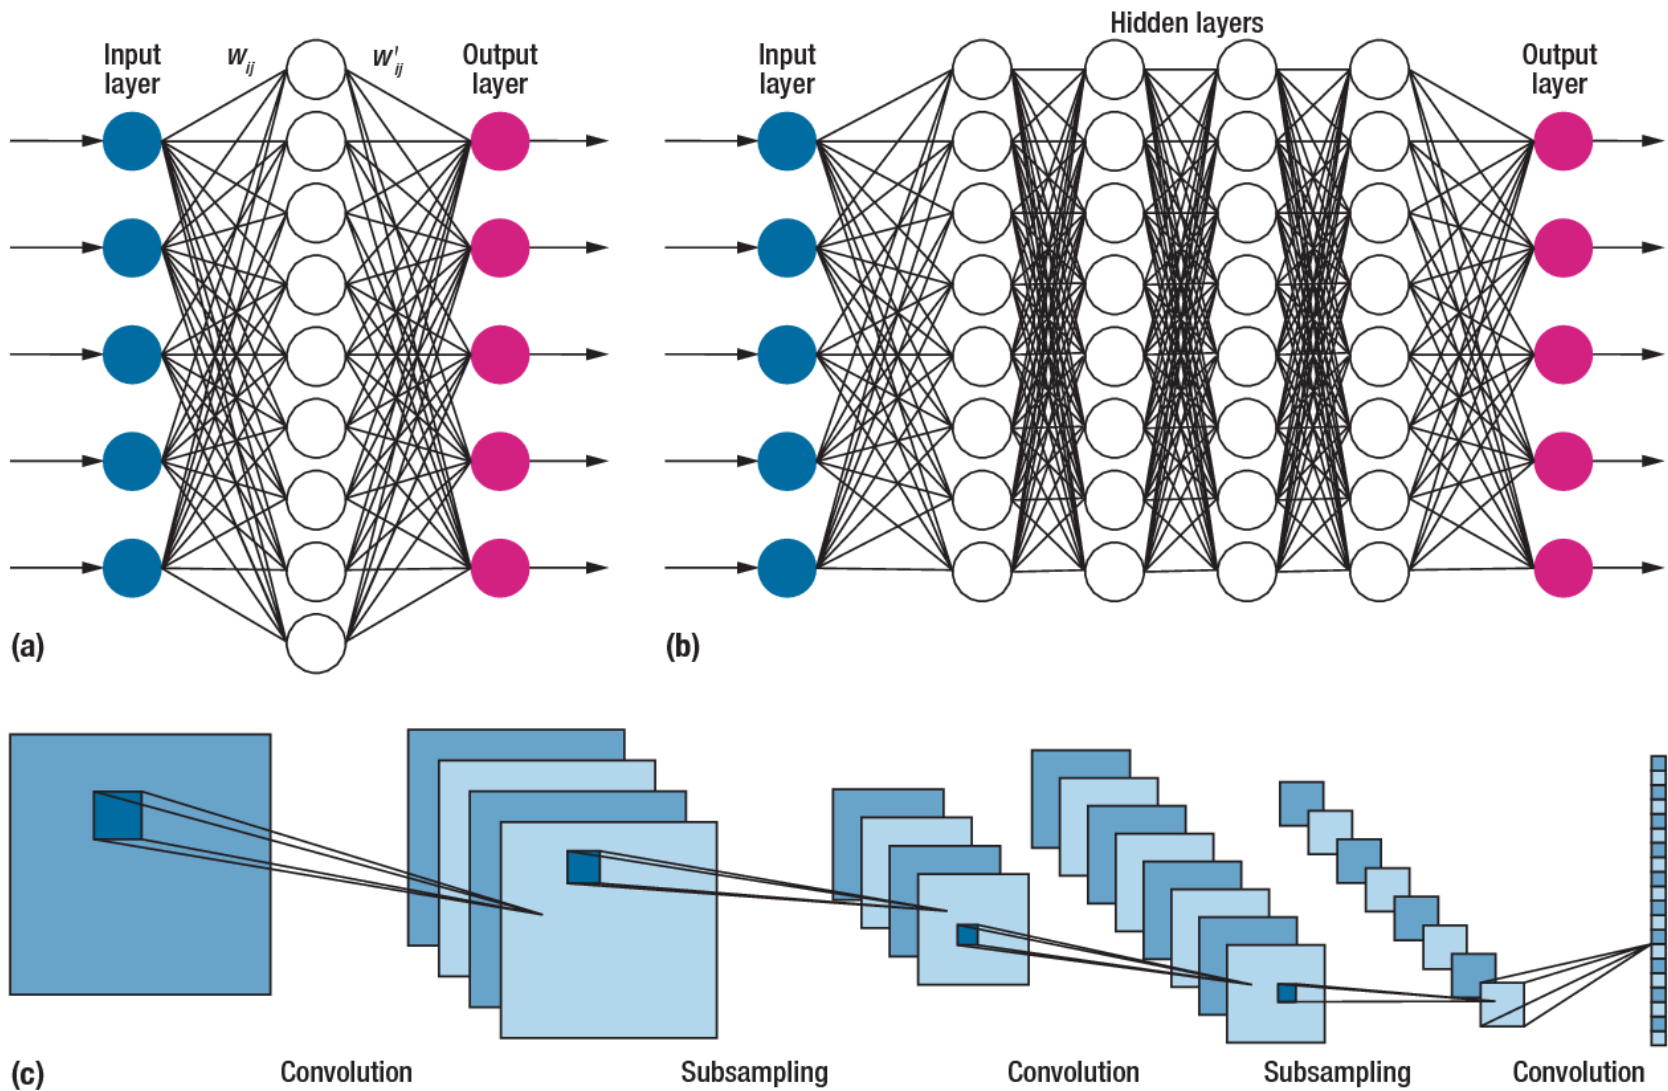


Mriežková štruktúra siete (Kohonenova sieť)



Hopfieldova sieť




a iné ...



Hlboké siete (Deep NN)

HW realizácie UNS





Činnosť mozgu pri vyhodnotení obrazu



Registrácia obrazu, vyhodnotenie obrazu a identifikácia objektu v niekoľkých „strojových taktoch“ mozgu.

Signály sa šíria súčasne (paralelne) cez milióny neurónov (asi cez 20 centier mozgu, 0.1s)

Umelá neurónová sieť na konvenčnom (Von Neumannovskom) počítači





Výpočet UNS


Von-neumannovským procesorom

(SW simulácia UNS)



Deep Neural Network



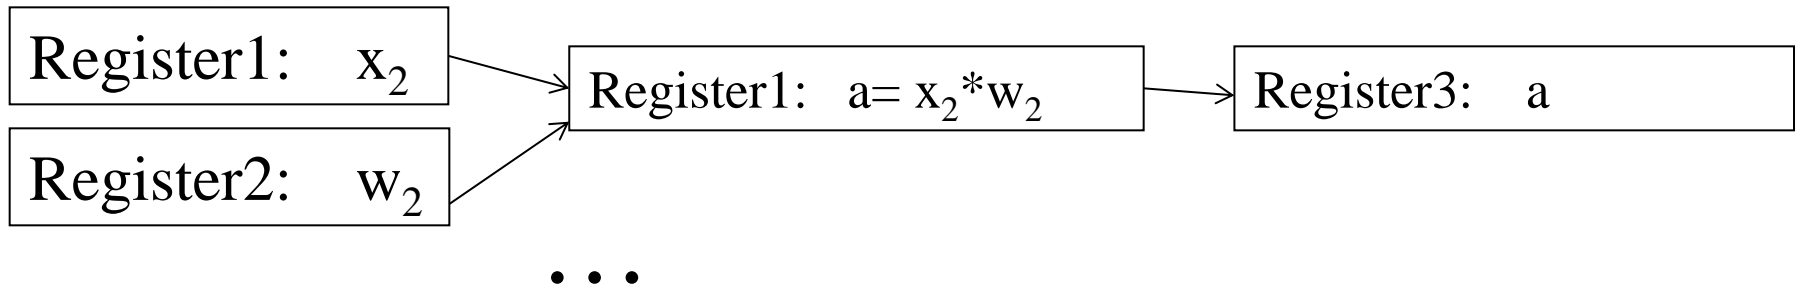

Von-Neumann Basic Structure:



Výpočet siete von-neumannovským procesorom




Výpočet siete von-neumannovským procesorom



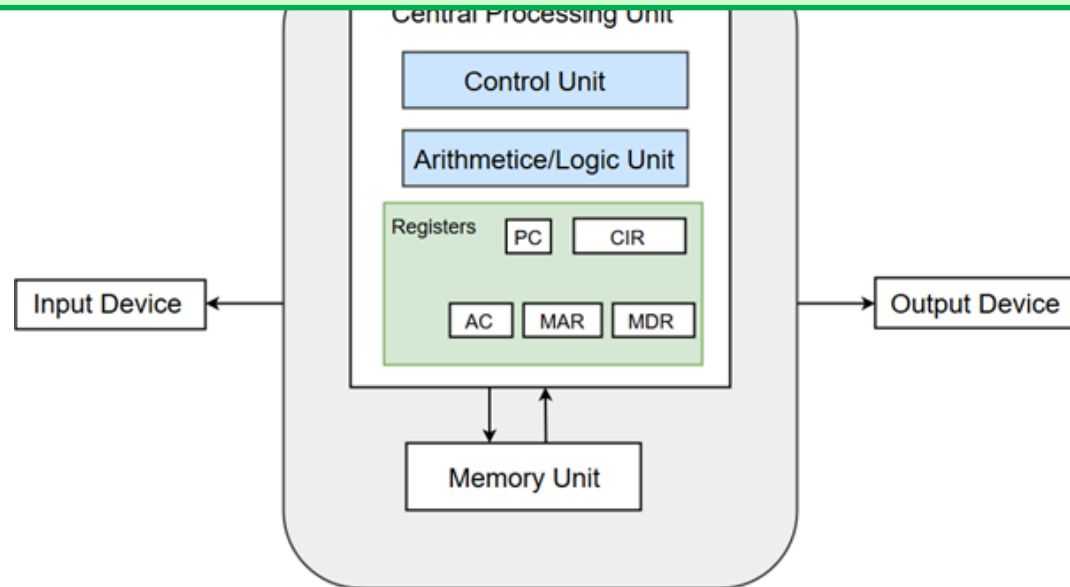

Výpočet UNS

Von-neumannovským procesorom



Poznámka:

**GPU – grafické procesory
vysoký stupeň paralelizácie,
väčší výkon pri výpočte UNS**




Na výpočet celej UNS potrebujeme milióny strojových taktov


Neuromorfické počítače

- Zväčša nie Von-Neumannovská architektúra počítača.
- Základnou stavebnou jednotkou sú neuróny a ich vzájomné masívne prepojenie v rôznych typoch architektúr.
- Rôzne technológie realizácie neurónov, analógový alebo číslicový princíp činnosti.
- Rôzne metódy učenia UNS.
- Reálne časový alebo akcelerovnaný režim.
- Intenzívny výskum a vývoj USA/Európa.
- Zatiaľ sa používajú iba na špecifické aplikácie.


Ultra-Low Power Brain-inspired Computing



Spintronic neuron/synapse



Memristor crossbar synapse





Hala Point (Intel)

Neuromorfný počítač, 1.15 Mld neurónov



Hybridná technológia = polovodiče + živé neuróny

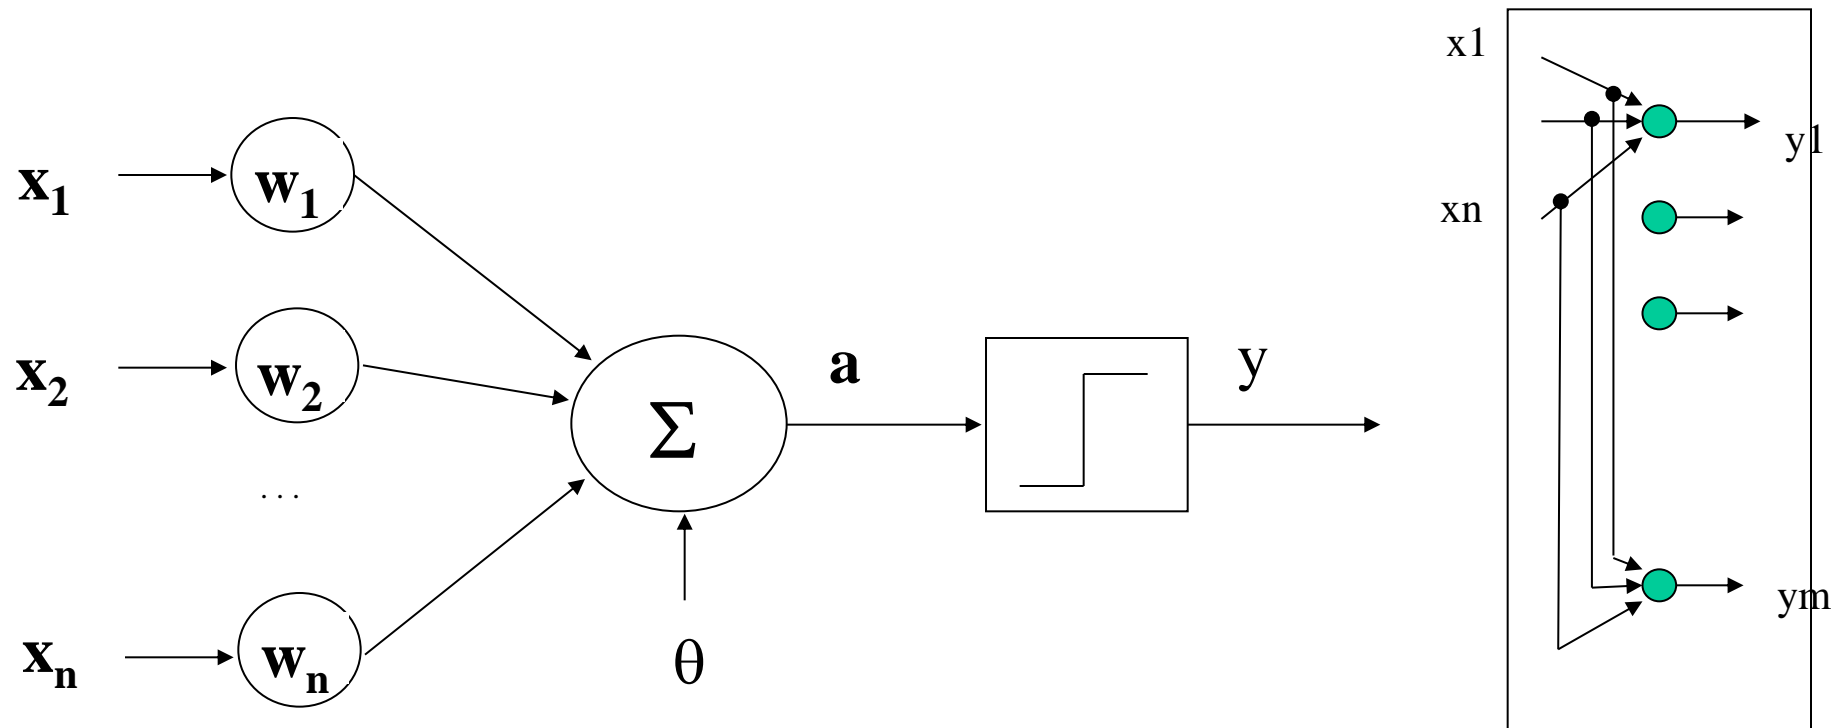
- počítač CL1 (Cortical Labs, Melbourne, Austrália)
- > 800 000 ľudských resp. myších neurónov
- 32 000 Eur
- vie sa naučiť hrať počítačové hry



Vybrané typy sietí, spôsoby ich učenia (trénovania) a ich použite

2.5 Jednovrstvové perceptrónové siete

Tieto siete sa tiež nazývajú "perceptrón". Predstavujú ich neuróny so skokovou aktivačnou funkciou usporiadané do jednej vrstvy.



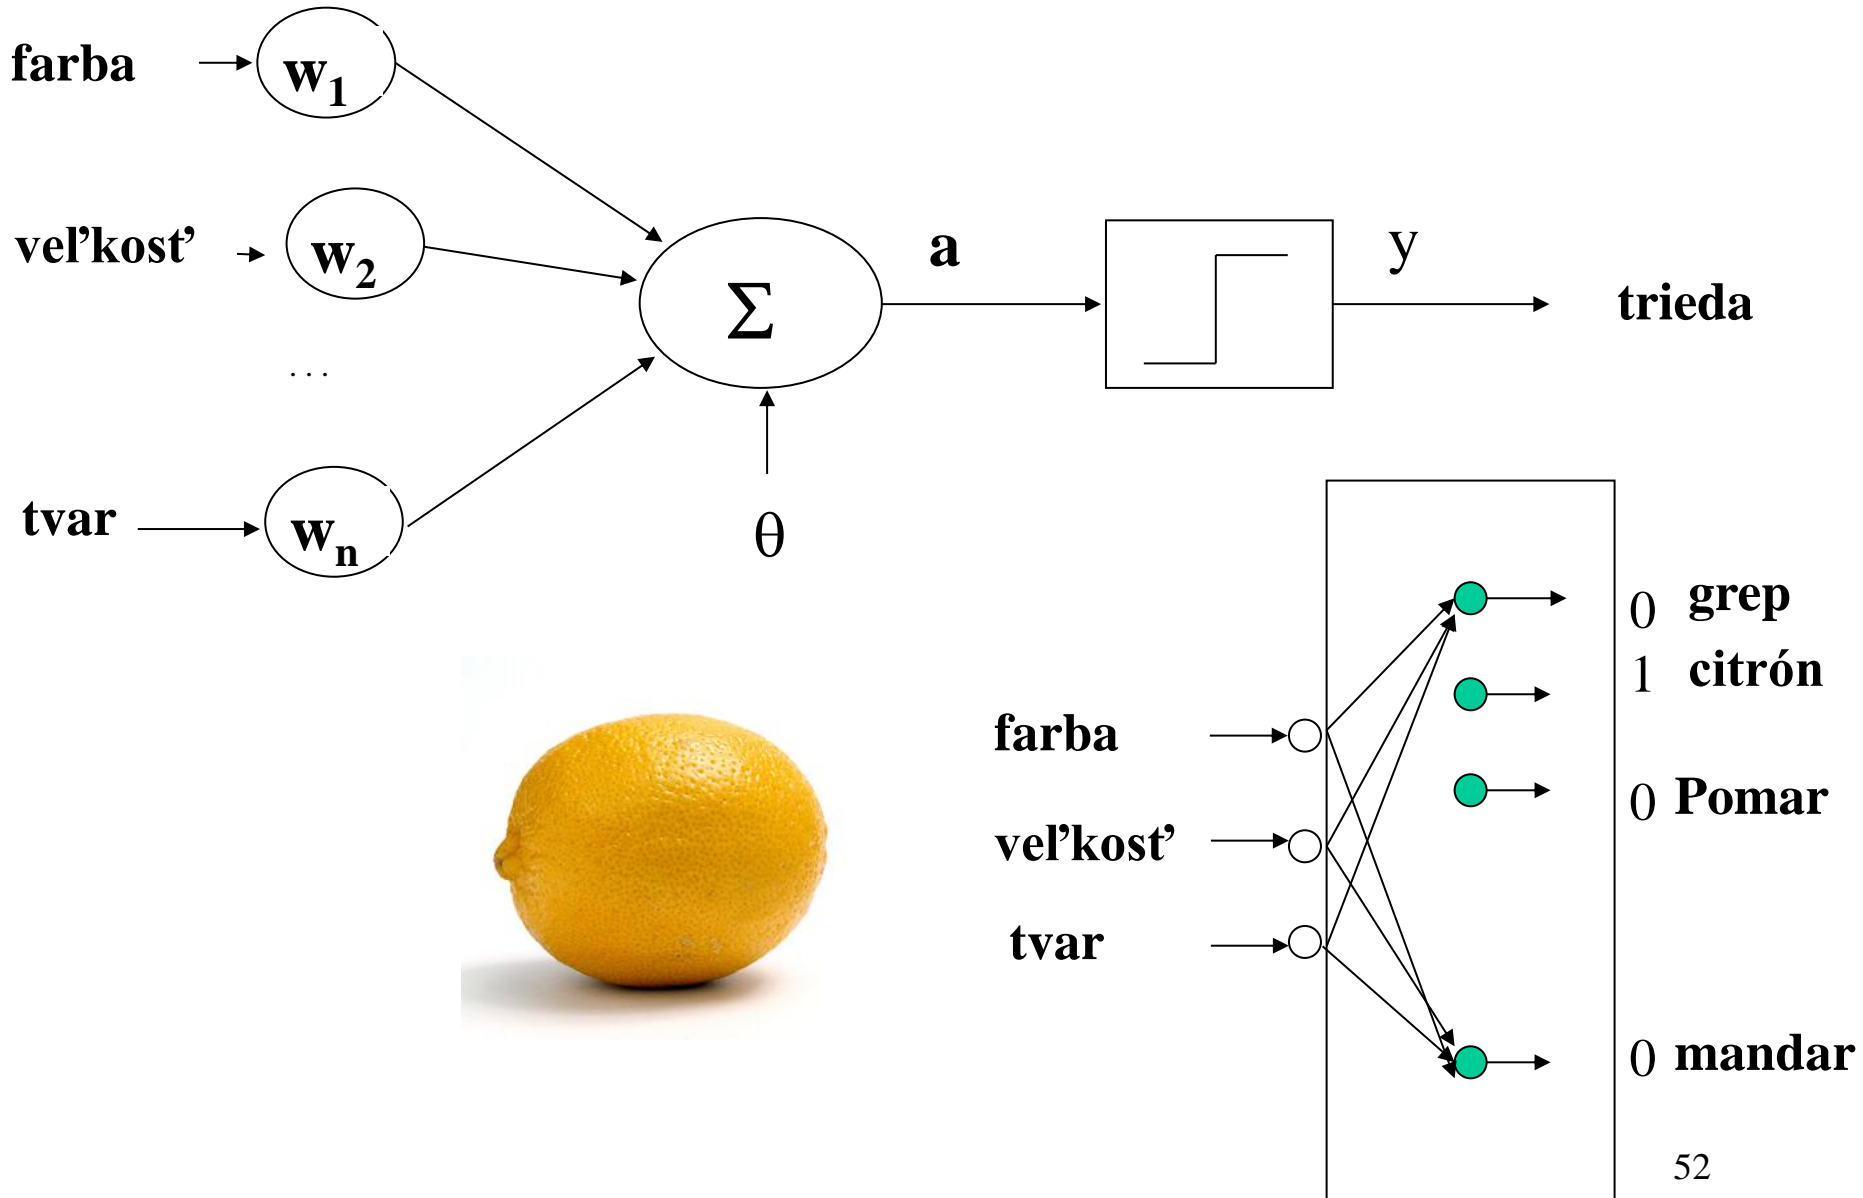
Táto sieť dokáže iba klasifikovať (kódovať) vstupné objekty (vzorky, vektory) - prirad'ovať ich do tried. Ak výstup i -teho neurónu y_i je 1, potom vstupný objekt, charakterizovaný vektorom x_i patrí do triedy C_i . Ak výstup je rovný 0 (alebo -1), potom do tejto triedy nepatrí.

Klasifikácia objektov do tried





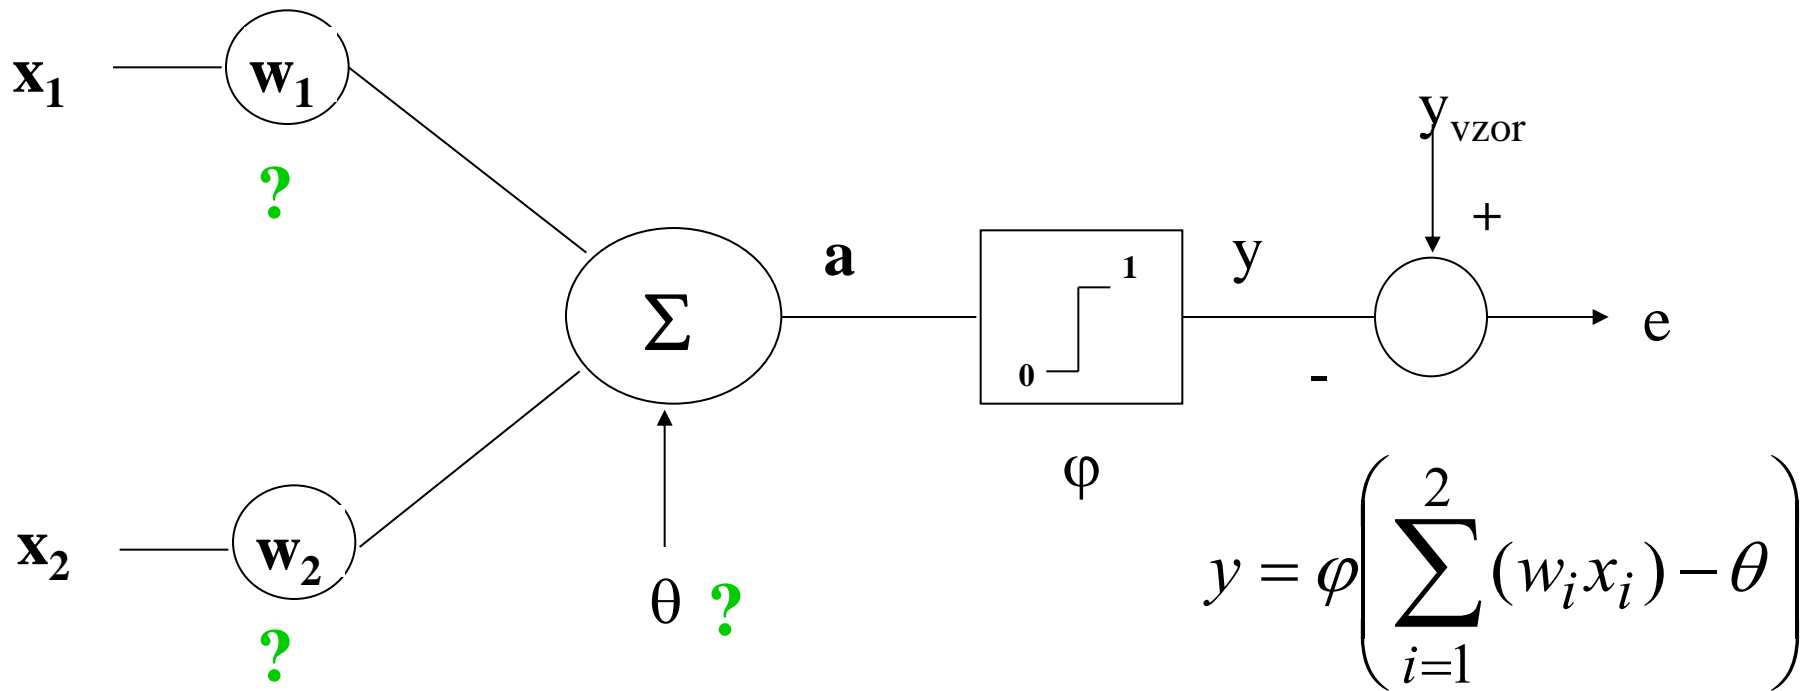
Klasifikácia objektov - triedenie ovocia



Príklad učenia 1-vrstvového perceptrónu

Úloha: *modelovanie logickej funkcie AND*

Model: *1 neurón, 2 vstupy / 1 výstup*

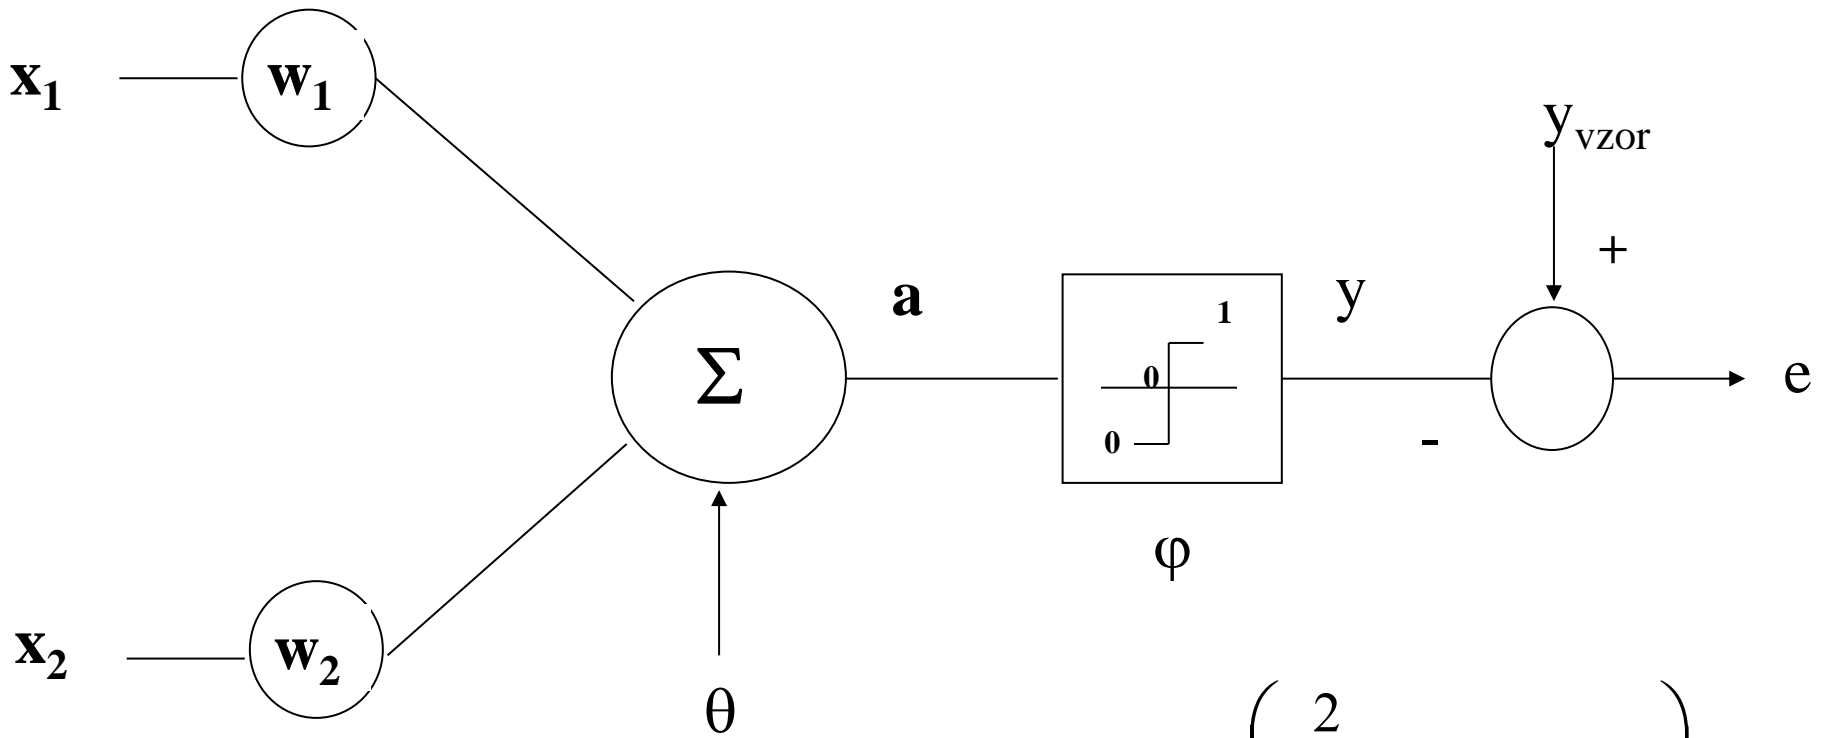


Logická funkcia AND
(trénovacie vzory)

VZOR	x₁	x₂	y_{vzor}
v₁	0	0	0
v₂	0	1	0
v₃	1	0	0
v₄	1	1	1

Postup tréovania

1. Inicializácia: nastavíme váhy w_1 a w_2 na náhodné hodnoty z rozsahu $(-0,5 ; 0,5)$.
2. Výpočet výstupu $y(v)$ pri vstupe vzoru v_1 (v_i)
3. Výpočet chyby $e = y_{\text{vzor}} - y$.
4. Korekcia váh: $w_{j,\text{new}} = w_j + \Delta w_j$
 $\Delta w_j = \alpha \cdot x_j \cdot e ; j=1, 2$
5. Chod' na ďalší vzor (v_2, v_3, v_4)
6. Cyklus krokov 2-5 („epocha“) opakuj, kým chyba modelu nebude dostatočne malá.



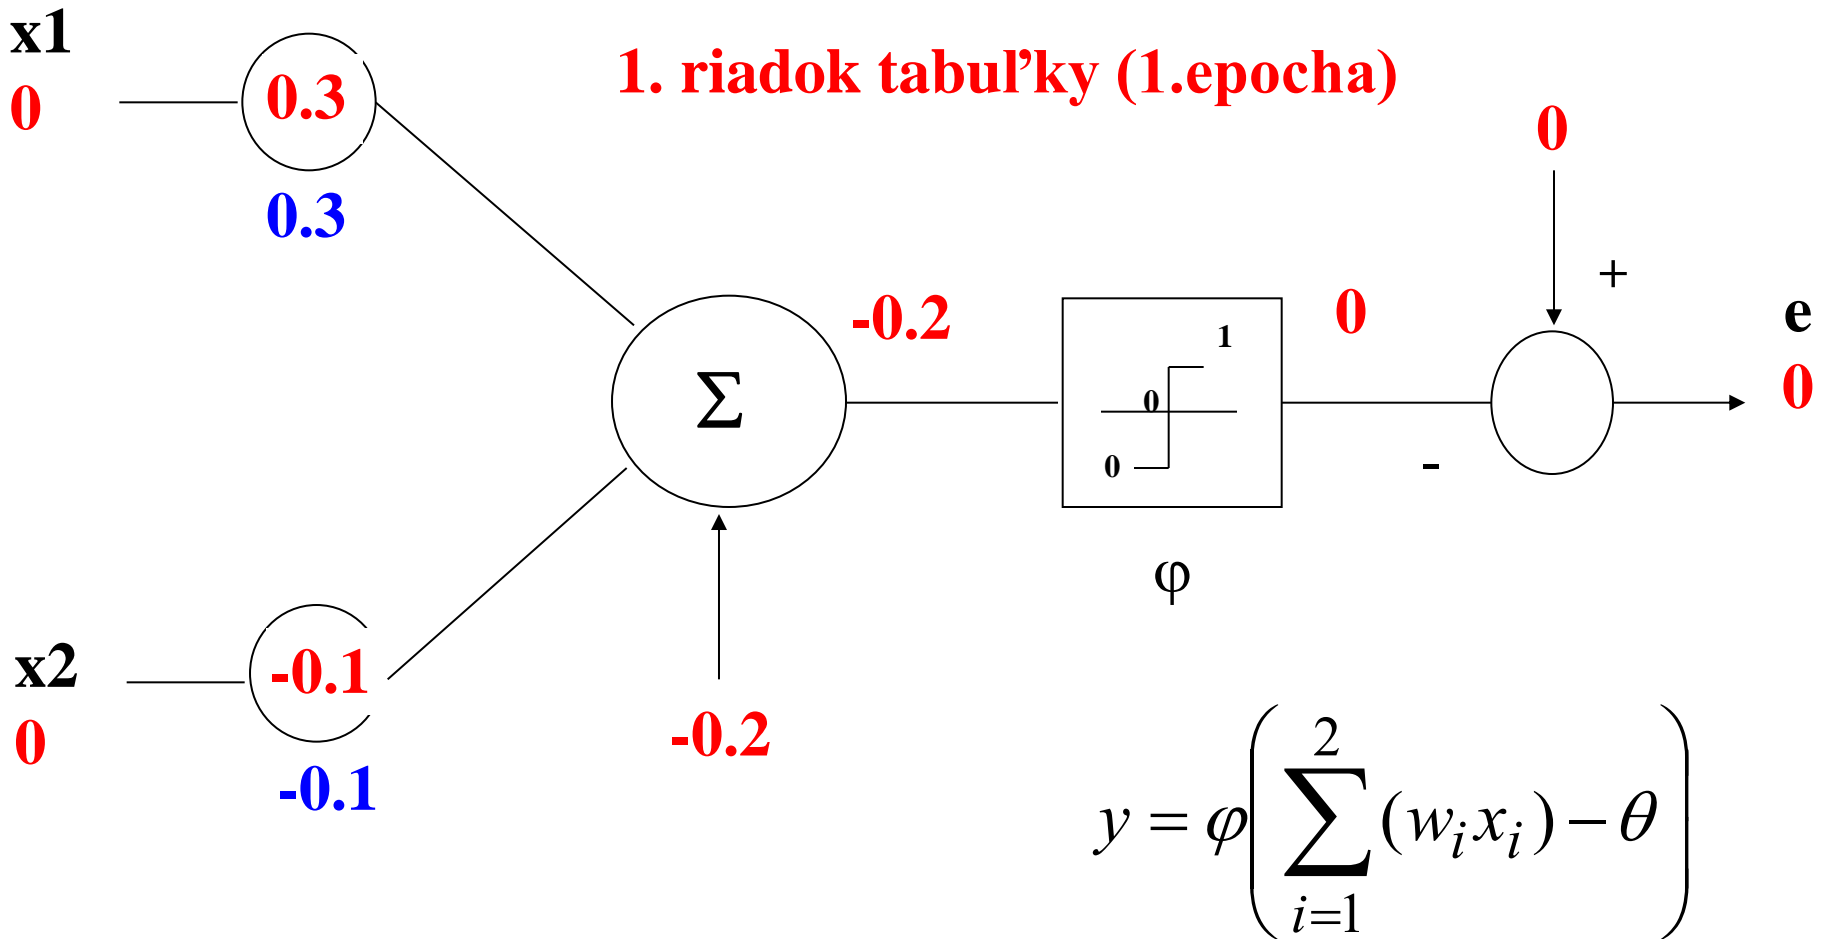
$$y = \phi \left(\sum_{i=1}^2 (w_i x_i) - \theta \right)$$

$$\begin{aligned} w_{j,\text{new}} &= w_j + \Delta w_j \\ \Delta w_j &= \alpha \cdot x_j \cdot e ; \quad j=1, 2 \end{aligned}$$

$\alpha=0,1$
 $\theta=0,2$

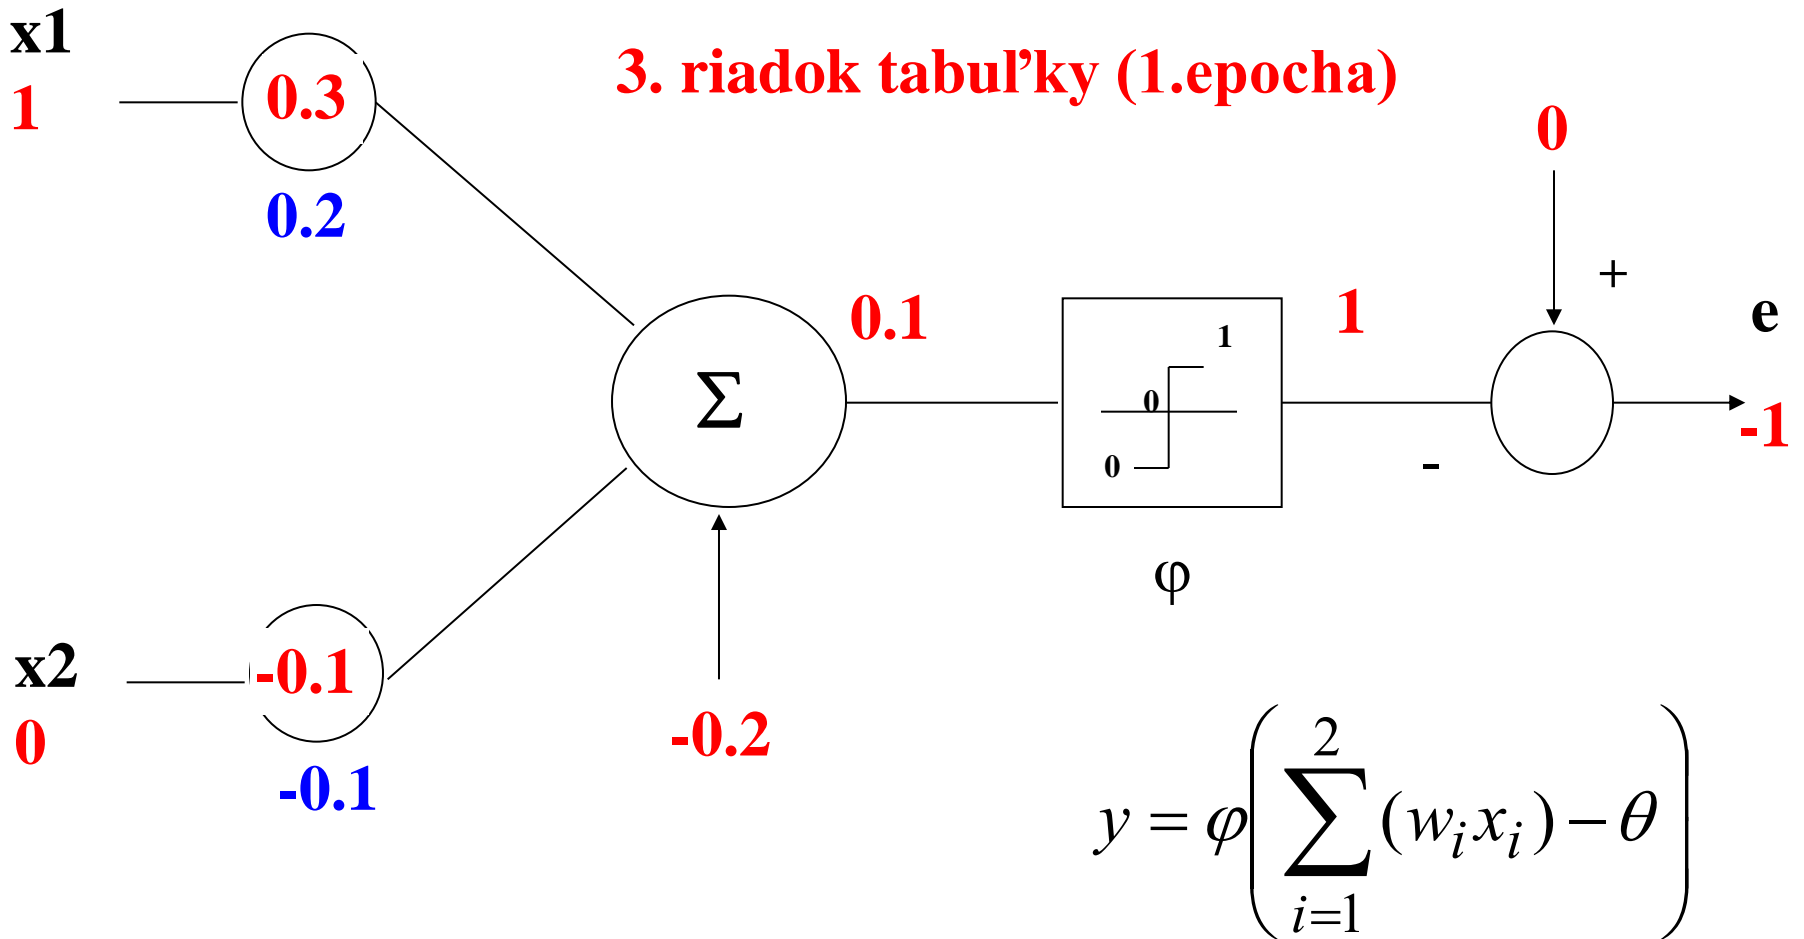
Epocha	x_1	x_2	Požad. y_v	Staré w_1	Staré w_2	Aktual. y	Chyba $e=y_v-y$			Nové w_1	Nové w_2		
1	0	0	0	0,3	-0,1	0	0			0,3	-0,1		
	0	1	0	0,3	-0,1	0	0			0,3	-0,1		
	1	0	0	0,3	-0,1	1	-1			0,2	-0,1		
	1	1	1	0,2	-0,1	0	1			0,3	0		
2	0	0	0	0,3	0	0	0			0,3	0		
	0	1	0	0,3	0	0	0			0,3	0		
	1	0	0	0,3	0	1	-1			0,2	0		
	1	1	1	0,2	0	1	0			0,2	0		
3	0	0	0	0,2	0	0	0			0,2	0		
	0	1	0	0,2	0	0	0			0,2	0		
	1	0	0	0,2	0	1	-1			0,1	0		
	1	1	1	0,1	0	0	1			0,2	0,1		
4	0	0	0	0,2	0,1	0	0			0,2	0,1		
	0	1	0	0,2	0,1	0	0			0,2	0,1		
	1	0	0	0,2	0,1	1	-1			0,1	0,1		
	1	1	1	0,1	0,1	1	0			0,1	0,1		
5	0	0	0	0,1	0,1	0		0		0,1	0,1		
	0	1	0	0,1	0,1	0		0		0,1	0,1		
	1	0	0	0,1	0,1	0		0		0,1	0,1		
	1	1	1	0,1	0,1	1		0			0,1	0,1	

$w_{j,new} = w_j + \Delta w_j$ $\Delta w_j = \alpha \cdot x_j \cdot e$; $j=1, 2$



$$\Delta w_j = 0.1 x_j e = 0; \quad j=1, 2$$

$$w_{j,\text{new}} = w_j + \Delta w_j = 0.3 \text{ resp. } -0.1$$




$$\Delta w_j = 0.1 x_j e = -0.1; \quad j=1, 2$$

$$w_{j,\text{new}} = w_j + \Delta w_j = 0.3 - 0.1 = 0.2 \text{ resp. } -0.1$$

$\alpha=0,1$
 $\theta=-0,2$

Epocha	x_1	x_2	Požad. y_v	Staré w_1	Staré w_2	Aktual. y	Chyba $e=y_v-y$			Nové w_1	Nové w_2		
1	0	0	0	0,3	-0,1	0	0			0,3	-0,1		
	0	1	0	0,3	-0,1	0	0			0,3	-0,1		
	1	0	0	0,3	-0,1	1	-1			0,2	-0,1		
	1	1	1	0,2	-0,1	0	1			0,3	0		
2	0	0	0	0,3	0	0	0			0,3	0		
	0	1	0	0,3	0	0	0			0,3	0		
	1	0	0	0,3	0	1	-1			0,2	0		
	1	1	1	0,2	0	1	0			0,2	0		
3	0	0	0	0,2	0	0	0			0,2	0		
	0	1	0	0,2	0	0	0			0,2	0		
	1	0	0	0,2	0	1	-1			0,1	0		
	1	1	1	0,1	0	0	1			0,2	0,1		
4	0	0	0	0,2	0,1	0	0			0,2	0,1		
	0	1	0	0,2	0,1	0	0			0,2	0,1		
	1	0	0	0,2	0,1	1	-1			0,1	0,1		
	1	1	1	0,1	0,1	1	0			0,1	0,1		
5	0	0	0	0,1	0,1	0		0		0,1	0,1		
	0	1	0	0,1	0,1	0		0		0,1	0,1		
	1	0	0	0,1	0,1	0		0		0,1	0,1		
	1	1	1	0,1	0,1	1		0			0,1	0,1	

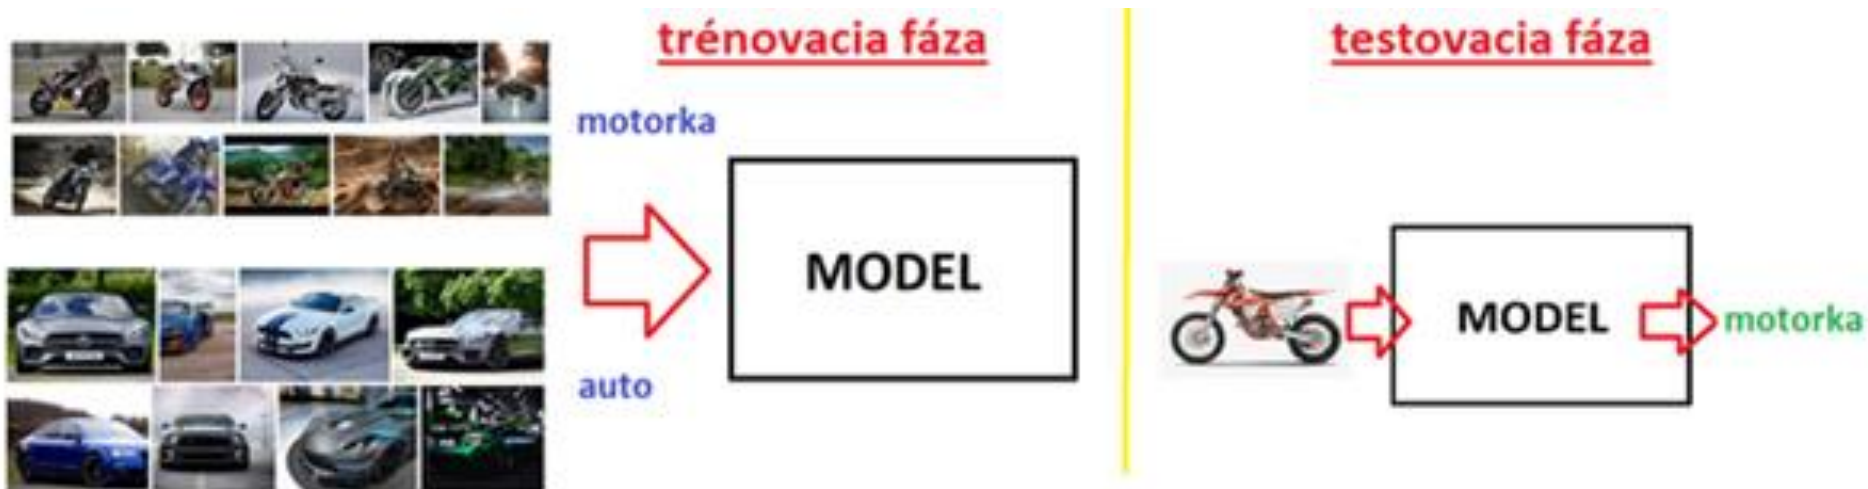
$w_{j,new} = w_j + \Delta w_j$ $\Delta w_j = \alpha \cdot x_j \cdot e$; $j=1, 2$




$$y = \phi \left(\sum_{i=1}^2 (w_i x_i) - \theta \right)$$

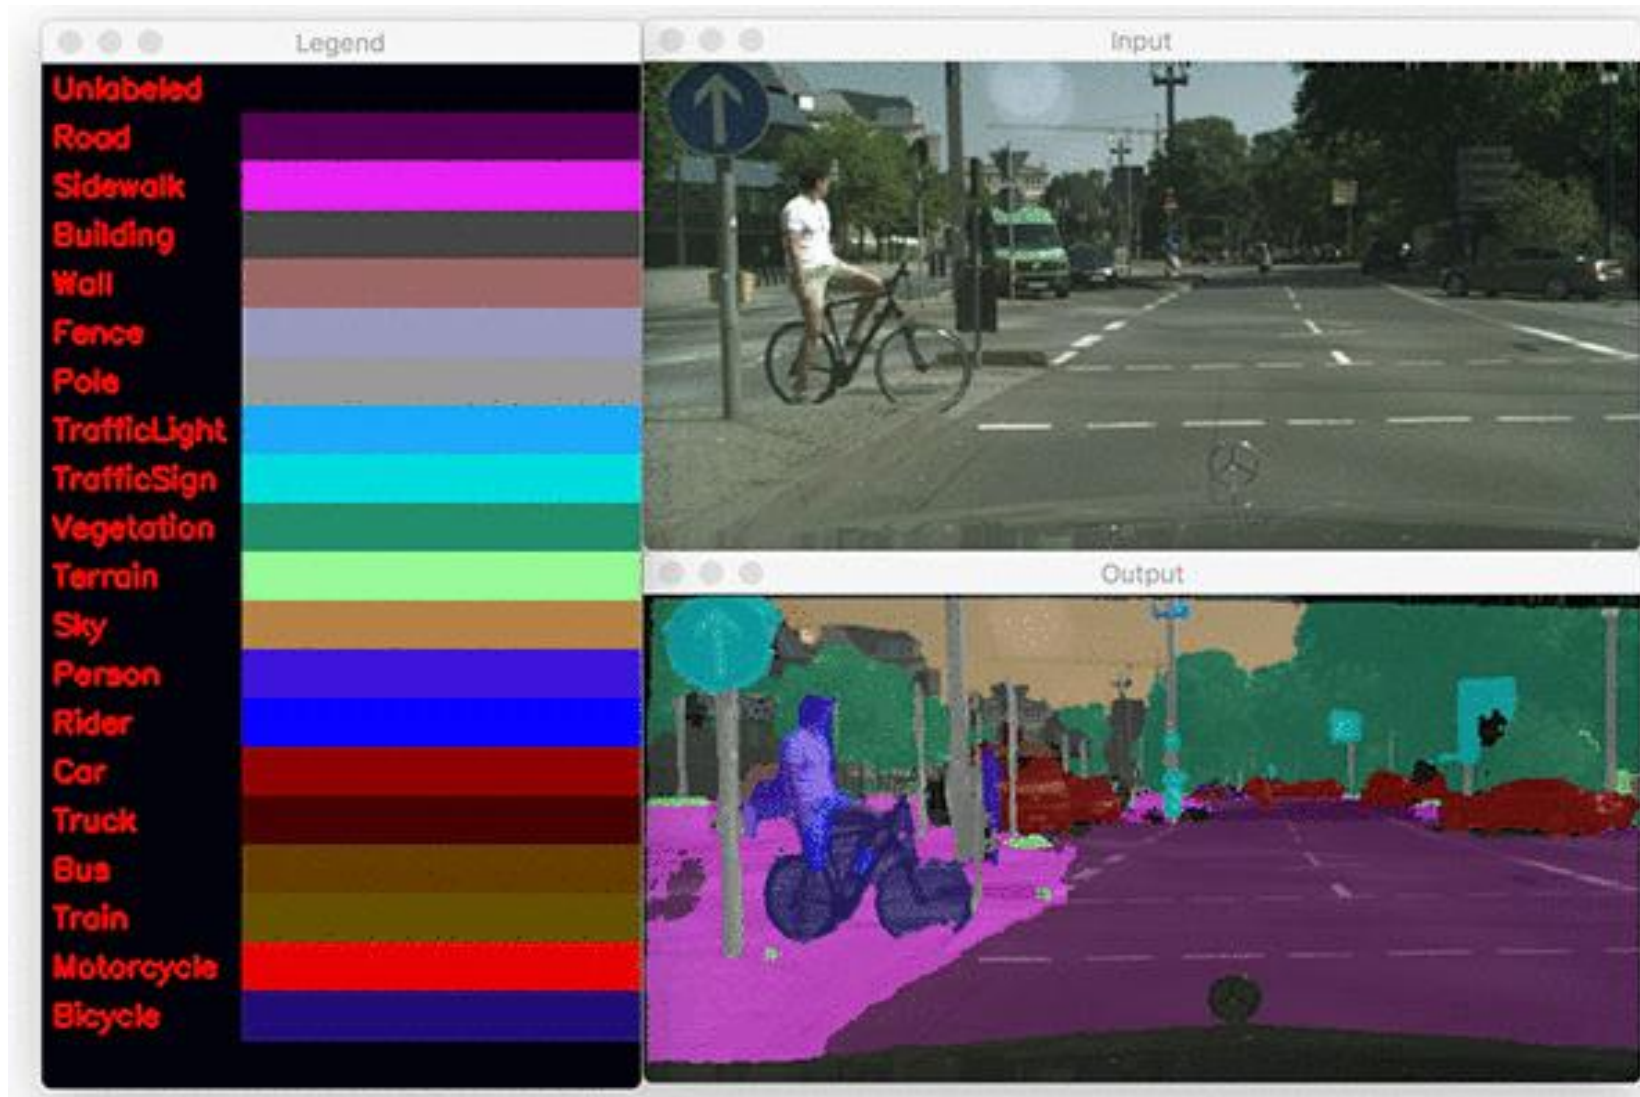
Prístupy učenia UNS

1. Učenie s učiteľom – sú k dispozícii vstupné dáta a im zodpovedajúce správne odpovede. UNS sa naučí tieto priradenia a neskôr dokáže zovšeobecňovať aj na iné zodpovedajúce priradenia.



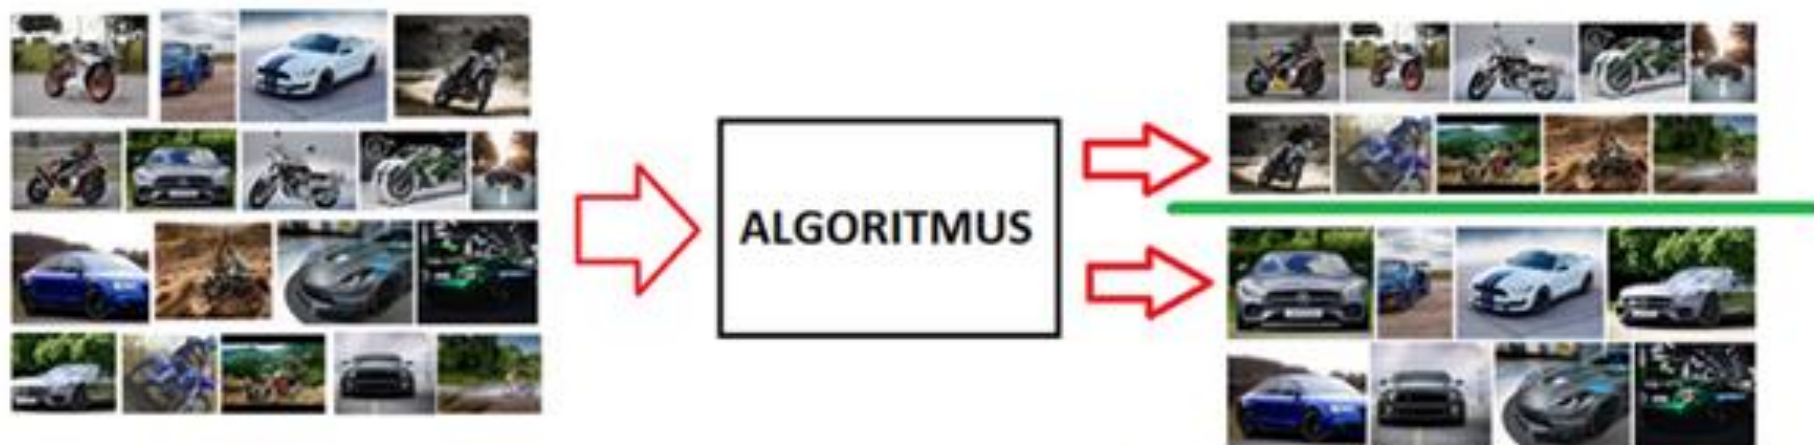
Učenie s učiteľom (supervised learning)







Naučená sémantická segmentácia scény

2. Učenie bez učiteľa – sú k dispozícii iba vstupné dáta. UNS sa naučí hľadať spoločné znaky medzi nepomenovanými objektmi (zhlukovanie) alebo môžeme hľadať skryté súvislosti medzi skupinami objektov, asociačné pravidlá (asociácia)



Učenie bez učiteľa (nsupervised learning)



3. Posilňované učenie (reinforcement learning)

Tu nepoužívame žiadnu predpripravenú množinu tréningových dát, či už so správnymi odpoveďami alebo bez. Vytvoríme mechanizmus, ktorý sa v prostredí sám učí. Musíme určiť pravidlá správania sa prostredia (model prostredia) a ohodnocovací systém (kriteriálnu funkciu). Čiže musíme ohodnotiť, či nám aktuálne správanie vyhovuje alebo nie, v lepšom prípade vieme aj jemnejšie ohodnotiť, do akej miery nám vyhovuje. Následne nejakou metódou, napríklad pokus-omyl, skúšame rôzne možnosti alebo modifikujeme aktuálne riešenie a snažíme sa čo najlepšie prispôbiť podmienkam prostredia.

Príkladom posilňovaného učenia môže byť tvorba umelého hráča hry Dáma, Šach alebo Go. Určíme pravidlá hry, ktoré sa musia dodržiavať a spôsob odmeňovania za úspešné akcie, za vyhodené figúry či za výhru. Potom necháme počítač hrať hru, napríklad samého proti sebe, veľmi veľa krát, až dosiahneme vysoký stupeň majstrovstva. Dokonca taký, ktorý je nedosiahnuteľný človekom.



4. Neuro-evolúcia

Podobné ako posilňované učenie, ale na hľadanie riešenia (parametrov UNS) prostredníctvom minimalizácie kritériálnej funkcie sa využíva evolučný algoritmus.

Učenie mobilného robota pomocou neuro-evolúcie pohybovať sa v prostredí z A do B. Minimalizuj dráhu a kolízie s prostredím.

